

Gemeinsamer Schlussbericht

Teil II – Ausführliche Fassung

Zuwendungsempfänger:

Institut für Umwelt & Energie, Technik & Analytik e. V.



FZI Forschungszentrum Informatik



Förderkennzeichen:

16DKWN138A

16DKWN138B

Vorhabenbezeichnung:

Flexible Datenanalyse und Workflow-Designer zur Identifizierung von Chemikalien im Wasserkreislauf - **streamFind**

Laufzeit des Vorhabens:

01.09.2022 - 31.08.2025



Das diesem Bericht zugrundeliegende Vorhaben wurde mit Mitteln des Bundesministeriums für Forschung, Technologie und Raumfahrt und Europäische Union unter den Förderkennzeichen 16DKWN138A und 16DKWN138B gefördert. Die Verantwortung für den Inhalt dieser Veröffentlichung liegt bei den Autoren.

Herausgeber:

Dr. Ricardo Cunha (IUTA), Dr.-Ing. Steffen Thoma (FZI)

Mit Text-, inhaltlichen oder Bildbeiträgen von:

Dr. Thorsten Teutenberg (IUTA)

MSc Walter Laurito (FZI)

Das Projekt „Flexible Datenanalyse und Workflow-Designer zur Identifizierung von Chemikalien im Wasserkreislauf – streamFind“

- wurde gemeinschaftlich bearbeitet von

- Institut für Umwelt & Energie, Technik & Analytik e. V., Bliersheimer Str. 58 - 60, 47229 Duisburg
- FZI Forschungszentrum Informatik, Haid-und-Neu-Str. 10-14, 76131 Karlsruhe

- wurde vom Bundesministerium für Forschung, Technologie und Raumfahrt (BMFTR) und Europäische Union (EU) im Rahmen der

- Richtlinie „Stärkung Datenkompetenzen für den wissenschaftlichen Nachwuchs“

- und vom VDI/VDE Innovation + Technik GmbH Projektträger betreut

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt



Finanziert von der
Europäischen Union
NextGenerationEU

Inhaltsverzeichnis

1. Einleitung	4
1.1. Hintergrund und Motivation	4
1.2. Zielsetzung des Projekts	8
1.3. Aufbau des Berichts	9
2. Arbeitspakete	9
2.1. Arbeitspaket 1 – Setup	9
2.2. Arbeitspaket 2 – streamFind Plattform	10
2.3. Arbeitspaket 3 – streamFind Frontend	20
2.3.1. Einleitung	20
2.3.2. Projekt- und Analysemanagement	21
2.3.3. Workflow-Assembly	22
2.3.4. Modulare grafische und logische Darstellung der Ergebnisse	23
2.3.5. Berichts- und Audit-Trail-Seiten	24
2.4. Arbeitspaket 4 – Schnittstellen	25
2.5. Arbeitspaket 5 – Integration Basis-Workflow	28
2.6. Arbeitspaket 6 – Erweiterung	32
2.6.1. Einleitung	32
2.6.2. Algorithmus zur Korrektur der Matrixunterdrückung	33
2.6.3. Algorithmus für Fold-Change-Analyse	35
2.6.4. Integration von MetFrag zur in-silico-Identifizierung von Chemikalien	37
2.6.5. Integration der Erzeugung von Transformationsprodukten	38
2.7. Arbeitspaket 7 – Berichterstellung	39
2.8. Arbeitspaket 8 – Verbreitung	40
2.8.1. Einleitung	40
2.8.2. Austauschaktivitäten	40
2.8.3. Extension	43
3. Zusätzliche Arbeiten außerhalb des ursprünglichen Plans	44
3.1. Einleitung	44
3.2. Quantifizierung von Biopharmazeutika mit LC-UV-Daten	44
3.3. Identifizierung intakter monoklonaler Antikörper mittels LC-HRMS	47
3.3.1. Framework zur Verarbeitung von Raman-Spektroskopiedaten	50
3.4. Framework für die Analyse von maschinellem Lernen	51
4. Nachhaltigkeit und Kontinuität der Projektergebnisse	52
5. Fazit	53

1. Einleitung

1.1. Hintergrund und Motivation

Der zunehmende Gebrauch und die Vielfalt an persistenten, mobilen und toxischen anthropogenen Chemikalien stellen eine Bedrohung für die Umwelt, das Trinkwasser und folglich auch für die öffentliche Gesundheit dar.^{1,2} Die EU-Verordnung Nr. 1907/2006 (REACH)³ wurde geschaffen, um neue besorgniserregende Schadstoffe (CEC - Chemicals of Emerging Concern) wie Arzneimittel, Hormone, Per- und Polyfluoralkylsubstanzen (PFAS), Pestizide, Weichmacher, künstliche Süßstoffe, illegale Drogen usw. zu erfassen, zu bewerten und den Eintrag in die Umwelt zu reduzieren. Aktuell gibt es unter REACH über 23.000 gelistete Einzelstoffe, von denen nach Anhang XVII bereits über 1.000 gefährliche Stoffe, Gemische und Erzeugnisse in der Herstellung, bezüglich ihres Inverkehrbringens und/oder ihrer Verwendung eingeschränkt wurden.⁴ Dies ist jedoch nur ein Bruchteil der über 190 Millionen organischen und anorganischen Verbindungen,⁵ von denen nach Schätzungen von Wang et al. aus dem Jahr 2020 etwa 350.000 regelmäßig hergestellt und ca. 70.000 im täglichen Gebrauch sind,⁶ wodurch diese potentiell in den Wasserkreislauf eingetragen werden können. Hinzu kommt, dass Stoffe nicht unverändert in der Umwelt verbleiben, sondern in sog. Transformationsprodukte (TP, z. B. Metabolite und Oxidationsprodukte) umgewandelt werden, die mit einem potenziell hohen und meist unbekannten toxikologischen Risiko verbunden sind.^{7,8,9} Hauptquellen für persistente anthropogene CEC und TP in der aquatischen Umwelt sind kommunale und industrielle Einleitungen sowie diffuse Stoffeinträge (z. B. aus der Landwirtschaft). Ein zielgerichtetes Monitoring (Target-Analytik) aller Stoffeinträge ist nicht möglich. Daher beschränkt sich die Analytik zumeist auf eine Liste von prioritären oder in Verordnungen geregelten Stoffen. Zur Aufklärung von relevanten Stoffeinträgen

¹ Zahn, D. et al. (2019), *Water Research*, 150: 86–96. <https://doi.org/10.1016/j.watres.2018.11.042>.

² <https://www.umweltbundesamt.de/PMT-stoffe> (Zugriff am 17.11.2021)

³ EG 1907/2006 (REACH-Verordnung),

<https://eur-lex.europa.eu/legal-content/en/TXT/HTML/?uri=CELEX:02006R1907-20210101> (Zugriff am 17.11.2021).

⁴ <https://www.echa.europa.eu/substances-restricted-under-reach> (Zugriff am 18.11.2021).

⁵ <https://www.cas.org/cas-data/cas-registry> (Zugriff am 17.11.2021)

⁶ Wang et al. (2020), *Environmental Science & Technology*, 54(5): 2575-2584. <https://doi.org/10.1021/acs.est.9b06379>.

⁷ Rüdél, H. et al. (2020), *Environmental Sciences Europe*, 32:5, <https://doi.org/10.1186/s12302-019-0286-x>.

⁸ Kasonga, T. K. et al. (2021), *Journal of Environmental Management*, 277: 111485.

<https://doi.org/10.1016/j.jenvman.2020.111485>.

⁹ Zahn, D. et al. (2019), *Water Research*, 150: 86–96. <https://doi.org/10.1016/j.watres.2018.11.042>.

und Schadstoffbelastungen werden die wirkungsbezogene Analytik und das Non-Target-Screening (NTS) kombiniert.¹⁰

Beim NTS wird die hochauflösende Massenspektrometrie (HRMS, High-Resolution Mass Spectrometry) eingesetzt, um sowohl erwartete (Suspects) als auch unerwartete (Non-Targets) Stoffe in einer Wasserprobe nachzuweisen. Das NTS ist ein wichtiges Tool zum Nachweis und zur Katalogisierung von CEC und TP in der natürlichen Umwelt und in lebenden Organismen, aber auch bei der Anwendung von Sanierungstechnologien für Wasser-, Abwasser- und Grundwasserströme.¹¹ Das NTS wird in den letzten Jahren vermehrt im Bereich der Wasser- und Umwelttechnik zur Bewertung und Optimierung von Behandlungsprozessen als auch bei behördlichen Überwachungen eingesetzt. Aktuell erfolgt die Auswertung dieser sehr komplexen NTS-Datensätze auf Basis von zumeist proprietären als auch Open-Source Software-Tools. Eine umfassende Auswertung von Datensätzen, die mehrere zehntausend Features (Masse-zu-Ladungs-Verhältnisse m/z mit Retentionszeit und Intensitätsangabe) enthalten können, stellt die Fachexperten mit analytischer Grundausbildung bis heute vor große Herausforderungen. Selbst rudimentäre Datenverarbeitungs- und Statistiktools sowie chemometrische Ansätze, die in den entsprechenden analytischen Grundvorlesungen vermittelt werden, sind in der Praxis wenig verbreitet.

Gonzalez-Gaya et al. (2021)¹² fassten in einer Studie über Software und Fallstudien zu NTS bei Umweltfragen einen wesentlichen Nachteil mit folgendem Statement gut zusammen: *"the avoidance of black box processing, the enhancement of intercomparison exercises, and the higher transparency in the workflows, (...), are fundamental steps required to homogenize and facilitate the use of SNTS"* (wobei SNTS hier für Suspect- und Non-Target-Screening steht). Neben den Methoden zur Probenahme und -erfassung stellen die Datenverarbeitung, Datenspeicherung und Berichterstattung für viele Wissenschaftler aus den jeweils fachbezogenen Domänen die größten Hürden bei der Nutzung von NTS im Umweltbereich dar. Die Datenkompetenzen für den Umgang mit NTS sind nicht nur an datenwissenschaftliche Kenntnisse gebunden, sondern auch an die Qualitätssicherung, wie von Caballero-Casero et al. (2021)¹³ und Schulze et al. (2020)¹⁴ kritisch festgestellt wurde. Die Qualitätssicherung in der Wasser- und Umweltanalytik ist aufgrund der großen Vielfalt an probenspezifischen Matrixstörungen (unspezifische, tagesaktuell schwankende

¹⁰ Baetz, N. et al. (2024). Effect-directed analysis of endocrine and neurotoxic effects in stormwater depending discharges. *Water Research*, 265, 122169. <https://doi.org/10.1016/j.watres.2024.122169>

¹¹ Brack, W. et al. (2019), *Environmental Sciences Europe*, 31. <https://doi.org/10.1186/s12302-019-0230-0>.

¹² Gonzalez-Gaya, B. et al. (2021), *Analytical Methods*, 13(16): 1876-1904. <https://doi.org/10.1039/d1ay00111f>.

¹³ Caballero-Casero, N. et al. (2021), *Trends in Analytical Chemistry*, <https://doi.org/10.1016/j.trac.2021.116201>.

¹⁴ Schulze, B. et al. (2020), *Trends in Analytical Chemistry*, 133: 116063. <https://doi.org/10.1016/j.trac.2020.116063>.

Hintergrundsignale, die die Empfindlichkeit und Massengenauigkeit der HRMS beeinflussen) besonders wichtig. Witterungsbedingungen, geologische und geografische Informationen sind ebenso wie Prozessbedingungen von (Ab-)Wasseraufbereitungsverfahren wichtige Metainformationen. Die Integration solcher Metainformationen kann als essenziell betrachtet werden, um u. a. eine zielgerichtete Optimierung von (Ab-)Wasseraufbereitungsverfahren vorzunehmen. Bis auf wenige und in diesen Einzelfällen sehr rudimentäre Implementierungen von Metainformationen zur Auswertung und Ergebniskorrelation im NTS-Workflow ist den Antragstellern keine wissenschaftliche Initiative bekannt, die dieses seit Jahren bestehende Problem beheben will.

Wissenschaftlicher Output in der Form von NTS-Workflows und zugehöriger Open-Source Software-Code werden regelmäßig veröffentlicht.^{15,16,17} Die Zusammenfassung aller bislang erzielten Ergebnisse in einer für die Fachdomäne zugänglichen, umfassenden und offenen NTS-Software erfolgt nicht. Für die Übertragung und Anpassung dieser innovativen Werkzeuge ist datenwissenschaftliches Spezialwissen erforderlich. Dies führt dazu, dass innovative datenwissenschaftliche Ansätze von Chemikern, Ingenieuren und Umweltwissenschaftlern trotz ihres Potenzials ungenutzt bleiben. Gründe hierfür sind der Mangel an datenwissenschaftlichen Kompetenzen zur Standardisierung und Anpassbarkeit der NTS-Workflows, was die Nutzbarkeit und Verbesserung von NTS für alle relevanten Fragestellungen in Bezug auf Wasser- und Umweltfragestellungen einschränkt.

Die HRMS ist die vorherrschende Technik, die für das NTS und die Identifizierung unbekannter Substanzen in der Umwelt verwendet wird. Zur eindeutigen Substanzidentifizierung wird zwar versucht, orthogonale Techniken wie Nahinfrarot- und Raman-Spektroskopie sowie die NMR einzubeziehen.^{18,19} Die Anwendung solcher Technologien in Bezug auf die definierte Fragestellung ist allerdings stark limitiert, da die Isolation, Aufreinigung und Aufkonzentrierung einer einzelnen Verbindung, die in einer komplexen Matrix in Spurenkonzentration vorliegt, extrem erschwert wird. Im Rahmen einer Bulk-Analyse der gesamten Probe können jedoch auch schwingungsspektroskopische Verfahren wichtige Metainformationen liefern. Der Schwerpunkt des streamFind-Projektes liegt daher auf der Datenverarbeitung der HRMS-Daten unter Einbeziehung aller verfügbaren Metainformationen.

¹⁵ Lotfi Khatoonabadi, R. et al. (2021), *Microchemical Journal*, 160(A): 105641. <https://doi.org/10.1016/j.microc.2020.105641>.

¹⁶ Alygizakis, N. A. et al. (2019), *Journal of Hazardous Materials*, 361: 19–29. <https://doi.org/10.1016/j.jhazmat.2018.08.073>.

¹⁷ Liigand, J. et al. (2020), *Scientific Reports*, 10(1): 1–10. <https://doi.org/10.1038/s41598-020-62573-z>.

¹⁸ Mendes, T. O. et al. (2015), *Food Analytical Methods*, 8(9): 2339–2346. <https://doi.org/10.1007/s12161-015-0121-y>.

¹⁹ Schievano, E. et al. (2019), *Food Chemistry*, 288: 96–101. <https://doi.org/10.1016/j.foodchem.2019.02.062>.

Ein allgemeiner Ansatz für die Verarbeitung von NTS-Daten ist in *Abbildung 1* dargestellt. Obwohl die tatsächliche Struktur der Datensätze und die angewandten Algorithmen je nach verfügbarer Software variieren, bleibt das grundlegende Konzept bestehen. Der Workflow basiert auf der Dekonvolution von MS-Profildaten in Deskriptoren aus Features zur Ermittlung von chromatografischen Peaks. In der Wasser- und Umweltanalytik liegen typischerweise viele Proben vor, die einen zusammenhängenden Datensatz darstellen. Dies sind beispielsweise Monitoring-Daten an definierten Probenahmestellen über einen langen Zeitraum, Daten in Bezug auf die räumliche Ausbreitung von Schadstoffen in einem Flussgebiet oder Datensätze, die einen mehrstufigen (Ab-)Wasserbehandlungsprozess abbilden. Bei mehreren Proben sind die folgenden Workflowschritte die Gruppierung und Normalisierung von Features für die gesamte Probenserie sowie ein Clustering der gruppierten Features in Komponenten unter Berücksichtigung ihrer Beziehung (d. h. natürliche Isotope und Addukte, wie in *Abbildung 1* rechte Spalte dargestellt). Jeder Peak bzw. jede Komponente entspricht einer Substanz, die beim NTS auch ohne Identifizierung anhand der ermittelten Summenformel und des charakteristischen Isotopenmusters probenübergreifend verglichen werden kann. Dies ist insbesondere beim Eintrag von unbekannten Chemikalien sehr wichtig, da somit sowohl eine retrospektive Bewertung von Proben als auch die Verfolgung einer Schadstofffahne in einem Gewässer ohne Referenzsubstanz möglich wird. Die hierfür erforderliche Komponentisierung von Features steht in vielen Software-Tools nicht zur Verfügung. Darüber hinaus stellen die unterschiedliche Datenstruktur und schwer vergleichbare Informationen der ausgegebenen Daten der verschiedenen Software-Tools ein Problem beim Vergleich von Proben dar.^{20,21,22}

²⁰ Hohrenk, L. L. et al. (2020), *Analytical Chemistry*, 92(2): 1898–1907.
<https://doi.org/10.1021/acs.analchem.9b04095>.

²¹ Schymanski, E. L. et al. (2015), *Analytical and Bioanalytical Chemistry*, 407(21): 6237–6255.
<https://doi.org/10.1007/s00216-015-8681-7>.

²² Hollender, J. et al. (2017), *Environmental Science & Technology*, 51(20): 11505–11512.
<https://doi.org/10.1021/acs.est.7b02184>.




Abbildung 1: Schema der drei grundlegenden Arbeitsschritte vom Rohspektrum bis zur endgültigen Liste der Komponenten bzw. Features.

Ein weiterer wichtiger Aspekt der Non-Target Analytik sind die aus den hochauflösenden massenspektrometrischen Datensätzen extrahierbaren MS/MS- bzw. MSⁿ-Daten. Solche MS/MS-Daten können für die Strukturaufklärung verwendet werden, was ein Schlüsselprozess bei der Identifizierung unbekannter Substanzen beim NTS ist. Die Integration von MS/MS-Daten in den Hauptdatensatz, der sich aus dem grundlegenden Workflow ergibt, hängt stark von der verwendeten proprietären Hersteller-Software und dem eingesetzten Analysengerät ab. Dies stellt ein großes Problem in Bezug auf die allgemeine Vergleichbarkeit von Datensätzen dar, die auf unterschiedlichen Geräten generiert werden.

1.2. Zielsetzung des Projekts

Das Ziel des Projekts „streamFind“ war die Entwicklung einer modularen Open-Source-Plattform, um die Implementierung von NTS für Wasser- und Umweltanalysen in einem kontinuierlich erweiterbaren Rahmen zu vereinfachen. Darüber hinaus sollten im Rahmen des Projekts grundlegende und fortgeschrittene NTS-Datenverarbeitungsmodulare entwickelt werden, um die NTS-Datenverarbeitung durch Benutzer bei spezifischen NTS-Anwendungsfällen zu unterstützen. Die endgültige Version des Rahmenprojekts ist das R-Paket StreamFind, das in diesem Bericht vorgestellt wird. Bei der Entwicklung des R-Pakets wurde besonderer Wert auf die Standardisierung modularer Datenverarbeitungsworkflows gelegt, um die Reproduzierbarkeit zu gewährleisten und den Austausch bewährter Verfahren für die Datenverarbeitung zwischen

Forschern zu fördern. Darüber hinaus wurde auf Einfachheit und Flexibilität bei der Erweiterung der Datenverarbeitungsfunktionen im Laufe der Zeit geachtet sowie auf die Integration einer umfassenden Dokumentation, um die Implementierung von Datenverarbeitungsalgorithmen zu erleichtern und den Erwerb von Datenkompetenzen und kritischem Denken zu ermöglichen.

1.3. Aufbau des Berichts

Die Projektarbeit wurde, wie in *Abbildung 2* dargestellt, in acht aufeinander aufbauenden Arbeitspaketen durchgeführt. Der Bericht fasst die wichtigsten Ergebnisse zusammen und erörtert die für jedes Arbeitspaket berücksichtigten Aspekte. Darüber hinaus werden die zusätzlichen Arbeiten außerhalb des ursprünglichen Projektplans sowie die Nachhaltigkeit und Kontinuität der Projektergebnisse diskutiert. Ziel ist es, die Anwendbarkeit in anderen Fachdomänen sowie die Erweiterbarkeit und die Wartungsstrategie des StreamFind-R-Pakets zu veranschaulichen.




Abbildung 2: Darstellung der Projektarbeitspakete und der jeweiligen Wechselwirkungen gemäß Projektantrag.

2. Arbeitspakete

2.1. Arbeitspaket 1 – Setup

Die administrativen Aufgaben sowie die Koordination und Kommunikation wurden in den ersten Monaten des Projekts festgelegt. Um eine effektive Zusammenarbeit und Kooperation zwischen den beiden Partnern zu gewährleisten, wurden wöchentliche Web-Meetings zwischen IUTA und

FZI geplant. Die Online-Meetings in den ersten Monaten konzentrierten sich darauf, ein gemeinsames Verständnis für das Format, die Struktur und die Variabilität von MS-Daten zu entwickeln. Darüber hinaus wurden grundlegende Prinzipien für die Umsetzung von NTS-Workflow-Strategien mit dem FZI ausgetauscht. Dies war entscheidend, um Verständnisprobleme aufgrund der grundlegend unterschiedlichen disziplinären Schwerpunkte von IUTA und FZI zu minimieren. Um den gegenseitigen Zugriff auf eine Entwicklungsumgebung, den Zugriff auf Demodaten und die Bereitstellung des entwickelten Softwaretools während der Projektlaufzeit und nach Projektende zu ermöglichen, wurden darüber hinaus Repositorien auf GitHub erstellt. Das Repository StreamFind²³ enthält ein voll funktionsfähiges R-Paket. Im Repository StreamFindData²⁴ sind Demodaten zur Unterstützung der auf der GitHub.io-Seite²⁵ von StreamFind verfügbaren Tutorials zu finden. Die technischen Anforderungen für die Entwicklung der Plattform wurden ebenfalls evaluiert, wobei der Schwerpunkt auf der Definition der Schnittstelle zwischen Datenverarbeitung und grafischer Benutzeroberfläche lag. Letztendlich wurde aufgrund ihrer Einfachheit, ihrer Zugänglichkeit für neue Benutzer, ihres robusten Entwicklungs- und Bereitstellungsframeworks sowie der Unterstützung durch die Community die Programmiersprache R sowohl für das Backend als auch für das Frontend ausgewählt. Ein entscheidender Aspekt für die Implementierung von StreamFind als R-Paket war die Objektstruktur und das funktionale Schnittstellensystem. R ist im Wesentlichen eine funktionale Sprache, was bedeutet, dass Funktionen isoliert und mit lokalen Objekten ausgewertet werden können. Obwohl R auf funktionale Programmierung ausgerichtet ist, ist es dank seiner Klassensysteme mit objektorientierter Programmierung (OOP) kompatibel. Die verfügbaren Objektklassensysteme (d. h. S3, S4 und R6) wurden getestet.²⁶ Die endgültige Implementierung beruht auf einer Synergie zwischen R6 und S3. R6 diente aufgrund seiner Einfachheit und geringeren Codeanforderungen im Vergleich zu S4 oder S3 als Hauptschnittstelle für den Benutzer. Die S3-Klasse wurde ausgewählt, um die Struktur der Backend-Objekte (z. B. Audit-Trail, Verarbeitungsmethoden und Analysen) zu steuern, da sie eine hohe Flexibilität bot, um den variablen Datenstrukturen gerecht zu werden.

2.2. Arbeitspaket 2 – streamFind Plattform

Das endgültige Plattform-Framework-Konzept (d. h. Backend) und das Klassensystem des StreamFind R-Pakets sind in *Abbildung 3* dargestellt. Die R6-Klassen (d. h. “Data Processing

²³ <https://github.com/odea-project/StreamFind>

²⁴ <https://github.com/odea-project/StreamFindData>

²⁵ <https://odea-project.github.io/StreamFind/>

²⁶ <https://adv-r.hadley.nz/index.html>

Engines“) werden als Hauptbenutzeroberfläche für Skripte verwendet, und die S3-Klassen (d. h. Metadata, AuditTrail, Analyses, Workflow, ProcessingStep und Results) werden als Ebene unterhalb der Hauptoberfläche eingesetzt. Das experimentelle S7-Klassensystem²⁷ wurde getestet und erwies sich als gut geeignet hinsichtlich Benutzerfreundlichkeit und Robustheit. Insbesondere die Selbstvalidierung war für die Implementierung geeignet. Allerdings kam die Entwicklung des S7-R-Pakets nicht rechtzeitig voran, um den Dokumentationsanforderungen des StreamFind-Projekts in Arbeitspaket sieben gerecht zu werden. Vor diesem Hintergrund haben wir uns erneut für S3 entschieden. Sollten jedoch weitere Entwicklungen an S7 vorgenommen werden, würde eine Umstellung der StreamFind-Implementierung zugutekommen.




Abbildung 3: Abschließendes Rahmenkonzept und Klassensystem des StreamFind R-Pakets.

Der Arbeitsplan für StreamFind konzentrierte sich auf die MS-Datenverarbeitung, jedoch wurde die Entwicklung des R-Pakets so durchgeführt, dass eine flexible Erweiterung auf andere Datentypen möglich ist, um viele Fachdomänen zu erreichen und eine Multi-Datenanalyse zu ermöglichen. Daher wurden eine Engine-R6-Klasse als Grundlage und anschließend Unterklassen implementiert, die sich auf einen bestimmten Datentyp konzentrieren (d. h. MS, Raman-Spektroskopie und einfache tabellarische Daten für die statistische Analyse). Für MS-Daten ist die MassSpecEngine R6-Klasse die Hauptschnittstelle und kann wie unten gezeigt initiiert werden:

²⁷ <https://github.com/RConsortium/S7>

```
engine <- MassSpecEngine$new(  
  metadata, workflow, analyses, centroid, levels  
)
```

wobei *engine* das Objekt ist, das als Hauptschnittstelle für die Datenanalyse und -verarbeitung erstellt wurde, *MassSpecEngine\$new* die Funktion zum Starten einer neuen Engine für MS-Daten ist, *metadata*, *workflow* und *analyses* Argumente zum Generieren der jeweiligen oben beschriebenen S3-Klassen sind, *centroid* ein logisches Argument ist, um die Zentrierung auf Rohdaten anzuwenden, wenn MS-Daten aus einem Herstellerformat in das Open-Source-Format mzML konvertiert werden, und *levels* definiert, welche Ebene der MS-Daten (d. h. MS¹ und MS²) zentriert werden soll.

Wie bereits erwähnt, wurden S3-Klassen im Hintergrund implementiert, um die verschiedenen Aspekte eines Datenverarbeitungs- und Analyseprojekts zu verwalten. Metadata ersetzen die alten Projektüberschriften, um Projektinformationen zu verwalten. AuditTrail wird eingeführt, um die Nachvollziehbarkeit des Datenverarbeitungs-Workflows sowie der Änderungen an den Daten in der Engine zu verbessern. Analyses steht für Rohdaten oder die Verbindung zu Rohdaten (z. B. Speicherort von Rohdatendateien, die zu groß sind, um direkt geladen zu werden, und Verbindung zum Datenserver auf Basis von z. B. LADS OPC UA). Die Unterklassen der Analyseklasse werden implementiert, um die Struktur und Methoden für einen bestimmten Datentyp (z. B. massenspektrometrische Daten, spektroskopische Daten, chromatografische Daten, etc.) zu definieren. Dies ermöglicht ein hohes Maß an Flexibilität bei gleichzeitiger Beibehaltung einer harmonisierten Grundstruktur für die verschiedenen Datentypen, die im StreamFind R-Paket verarbeitet werden können. Unterklassen der Analyseklasse (z. B. MassSpecAnalyses, RamanAnalyses und StatisticAnalyses) werden verwendet, um Attribute und Methoden für die Analyse, Visualisierung und Berichterstattung von Daten und Ergebnissen zu spezifizieren. Die Klasse ProcessingStep wird als Oberklasse für alle verfügbaren Datenverarbeitungsmethoden für jeden Datentyp implementiert. Unterklassen von ProcessingStep werden dann implementiert, um Parameter und Validierung zu spezifizieren und eine flexible, aber harmonisierte Schnittstelle für alle verfügbaren Verarbeitungsmethoden zu schaffen. Die Klasse Workflow stellt eine geordnete Liste von Objekten der Klasse ProcessingStep dar und ist für die Überprüfung der Konformität der hinzugefügten Schritte und der Reihenfolge verantwortlich. Schließlich wird die Klasse Results implementiert, um die Ergebnisse für alle Verarbeitungsmaschinen zu harmonisieren. Anschließend werden Unterklassen erstellt, um die Ergebnisse einer bestimmten Workflow-Anwendung zu spezifizieren, wie in *Tabelle 1* dargestellt.

Tabelle 1: Unterklassen von „Analyses“ und zugehörige Unterklassen von „Results“ sowie Workflows, in denen sie verwendet werden, werden in diesem Bericht vorgestellt.

Unterklassen „Analyses“	Unterklassen „Results“	Workflows
MassSpecAnalyses	MassSpecResults_NonTargetAnalysis	NTS
	MassSpecResults_TransformationProducts	
MassSpecAnalyses	MassSpecResults_Spectra	Quantifizierung und Identifizierung monoklonaler Antikörper mittels LC-HRMS
	MassSpecResults_Chromatograms	
RamanAnalyses	RamanResults_Spectra	Qualitätskontrolle von Biopharmazeutika mit SEC- Raman-Daten
StatisticAnalyses	StatisticResults_PCA	Statistische Analyse von NTS- Featurelisten und Reinheitsanalyse von biopharmazeutischen Formulierungen
	StatisticResults_MRCALS	
	StatisticResults_KNN	

Die Implementierung der verschiedenen Klassen folgt einem harmonisierten Validierungsverfahren mit einer Reihe von Prüfungen auf strukturelle und inhaltliche Konformität, beginnend mit der übergeordneten S3-Klasse (z. B. Analyses) bis hin zu den untergeordneten S3-Klassen (z. B. MassSpecAnalyses). Es ist zu beachten, dass R6 über ein Selbstvalidierungs-Framework verfügt. Die Validierung steht dem Benutzer als Funktionsmethode unter Verwendung der Standard-S3-Verteilung zur Verfügung und ist für alle S3-Klassen in StreamFind verfügbar.

```
mtd <- Metadata(  
  list(  
    name = "NTS Project",  
    author = "Person",  
    description = "example"  
  )  
)
```

```
validate_object(mtd)
```

wobei *mtd* ein Objekt der Klasse *Metadata* ist, *Metadata* die Konstrukturfunktion, die eine Liste von Elementen entgegennimmt, die als Projektmetadata verwendet werden sollen. Die Funktion *validate_object* ist dann eine S3-Methode, die die Validierung des Objekts *mtd* auslöst. In diesem Fall werden beispielsweise Überprüfungen durchgeführt, um sicherzustellen, dass jedes Element der Liste die Länge eins hat.

In diesem und allen anderen Kapiteln, in denen wir die Entwicklung von StreamFind behandeln, werden die in Tabelle 2 beschriebenen experimentellen Dateien und der NTS-Anwendungsfall verwendet, um die Implementierung besser zu veranschaulichen. Die Dateien sind über das ergänzende StreamFindData R-Paket verfügbar, und eine kurze Übersicht über das Fallbeispiel findet sich im NTS-Artikel auf der StreamFind Webseite.²⁸ Der Anwendungsfall umfasst eine NTS-Studie, in der der Zulauf (*influent_neg* und *influent_pos*) und der Ablauf (*effluent_neg* und *effluent_pos*) einer Ozonisierungsanlage zur Abwasserbehandlung hinsichtlich der Entfernung von Mikroverunreinigungen und der potenziellen Anwesenheit oder Bildung von Transformationsprodukten untersucht werden. Zur Unterstützung der Verarbeitung wurden Blindmessungen (*blank_neg* und *blank_pos*) zur Hintergrundsubtraktion durchgeführt.

²⁸ https://odea-project.github.io/StreamFind/articles/demo_nts.html

Tabelle 2: Für die Demonstration verwendete Dateien, zugewiesene Replikations- und Blankproben sowie Art der MS-Daten, Polarität und Anzahl der Spektren. Die tatsächlichen Dateipfade werden nicht angezeigt. Darüber hinaus wurden die Dateien verkleinert, um die Demonstration zu vereinfachen.

Analyse	Replikate	Blind	Art	Polarität	Spektren
01_tof_ww_is_neg_blank-r001	blank_neg	blank_neg	MS/MS-DDA	-1	1914
01_tof_ww_is_neg_blank-r002	blank_neg	blank_neg	MS/MS-DDA	-1	1932
01_tof_ww_is_neg_blank-r003	blank_neg	blank_neg	MS/MS-DDA	-1	1941
01_tof_ww_is_pos_blank-r001	blank_pos	blank_pos	MS/MS-DDA	1	2504
01_tof_ww_is_pos_blank-r002	blank_pos	blank_pos	MS/MS-DDA	1	2491
01_tof_ww_is_pos_blank-r003	blank_pos	blank_pos	MS/MS-DDA	1	2504
02_tof_ww_is_neg_influent-r001	influent_neg	blank_neg	MS/MS-DDA	-1	1984
02_tof_ww_is_neg_influent-r002	influent_neg	blank_neg	MS/MS-DDA	-1	1995
02_tof_ww_is_neg_influent-r003	influent_neg	blank_neg	MS/MS-DDA	-1	1993
02_tof_ww_is_pos_influent-r001	influent_pos	blank_pos	MS/MS-DDA	1	2131
02_tof_ww_is_pos_influent-r002	influent_pos	blank_pos	MS/MS-DDA	1	2126
02_tof_ww_is_pos_influent-r003	influent_pos	blank_pos	MS/MS-DDA	1	2124
03_tof_ww_is_neg_o3sw_effluent-r001	effluent_neg	blank_neg	MS/MS-DDA	-1	1909
03_tof_ww_is_neg_o3sw_effluent-r002	effluent_neg	blank_neg	MS/MS-DDA	-1	1921
03_tof_ww_is_neg_o3sw_effluent-r003	effluent_neg	blank_neg	MS/MS-DDA	-1	1924
03_tof_ww_is_pos_o3sw_effluent-r001	effluent_pos	blank_pos	MS/MS-DDA	1	2046
03_tof_ww_is_pos_o3sw_effluent-r002	effluent_pos	blank_pos	MS/MS-DDA	1	2052
03_tof_ww_is_pos_o3sw_effluent-r003	effluent_pos	blank_pos	MS/MS-DDA	1	2048

Eine besondere Herausforderung bei der Initiierung eines MS-Datenverarbeitungsprojekts ist der Zugriff auf die eigentlichen Daten. Häufig werden die Daten vom MS-Gerät in einem spezifischen und i. d. R. proprietären Herstellerformat erfasst. Mit dem Open-Source-Programm msconvert²⁹ von ProteoWizard kann ein offener Datenstandard (d. h. mzML) erzeugt werden, jedoch muss die mzML-Datei weiterhin gelesen werden, um auf die MS-Daten zugreifen zu können. Bestehende

²⁹ <https://proteowizard.sourceforge.io/tools/msconvert.html>

Tools (z. B. das mzR-Paket³⁰) kamen aufgrund der geringen Lesegeschwindigkeit, der schwierigen Installation und Integration oder der mangelnden Automatisierung beim Lesen der Daten aus einem Funktionsaufruf nicht in Frage. Vor diesem Hintergrund wurde im Rahmen des Projekts eine C++ Library entwickelt, um die Extraktion von MS-Daten aus mzML- und mzXML-Datendateien zu verbessern. Ein Vergleich der Lesegeschwindigkeit von C++, integriert in StreamFind, mit dem mzR-Paket und dem RaMS-Paket³¹ ist in *Abbildung 4* dargestellt, um die erzielte Geschwindigkeitssteigerung zu veranschaulichen. Die C++ Library wurde über das Rcpp-Paket³² in StreamFind integriert, was den Weg für die weitere Konvertierung von in R entwickelten Algorithmen nach C++ während des Projekts ebnete und die Verarbeitungsgeschwindigkeit für rechenintensive Verarbeitungsschritte drastisch verbesserte.




Abbildung 4: Vergleich der Lesegeschwindigkeit zwischen dem in StreamFind integrierten C++ und dem mzR-Paket sowie dem RaMS-Paket.

Das aktualisierte Skript zur Erstellung einer MassSpecEngine für das NTS-Demonstrationsprojekt ist unten aufgeführt. Die erstellte Engine wird im gesamten Bericht verwendet, um die Entwicklung und Implementierung des StreamFind R-Pakets zu veranschaulichen und zu demonstrieren.

³⁰ <https://www.bioconductor.org/packages/release/bioc/html/mzR.html>

³¹ <https://cran.r-project.org/web/packages/RaMS/index.html>

³² <https://cran.r-project.org/web/packages/Rcpp/index.html>

```
files <- StreamFindData::get_ms_file_paths()
files <- files |> stringr::str_detect("blank|influent|o3sw")

ms <- MassSpecEngine$new(
  metadata = list(
    name = "Wastewater Ozonation Showcase",
    author = "Ricardo Cunha",
    description = "Demonstration project"
  ),
  workflow,
  analyses = files,
  centroid = TRUE,
  levels = c(1, 2)
)

rpls <- rep(c("blank_neg", "blank_pos", "influent_neg", "influent_pos",
"effluent_neg", "effluent_pos"), each = 3) # Vektor der Namen der
Replikationsgruppen
blks <- rep(c("blank_neg", "blank_pos"), each = 3, times = 3) # Vektor
der Namen der Blindgruppen

ms$Analyses <- set_replicate_names(ms$Analyses, rpls)
ms$Analyses <- set_blank_names(ms$Analyses, blks)
```

wobei *files* die vollständigen Pfade zu allen in StreamFindData verfügbaren MS-Demodateien sind, die dann auf Dateien unterteilt werden, deren Zeichenfolge mit den Schlüsselwörtern „blank“, „influent“ und „o3sw“ übereinstimmt. *ms* ist eine MassSpecEngine, die die Dateien als MassSpecAnalyses und Metadaten enthält. Es wird eine automatische Erkennung von Herstellerdateien durchgeführt. Wenn diese erfolgreich ist, erfolgt die Konvertierung in mzML und die Zentrierung der MS¹- und MS²-Daten. Anschließend werden zwei Vektoren erstellt, um die korrekten Dateireplikationsgruppen und die zugehörigen Blindgruppen über die dedizierten S3-Methoden *set_replicate_names* und *set_blank_names* zuzuweisen.

Die Unterklasse „Engine“ ist, wie bereits erwähnt, die Hauptschnittstelle, über die Benutzer auf die Objekte der Klasse „S3“ zugreifen können, um Aufgaben auszuführen, Visualisierungen zu

erstellen und Daten zu exportieren. Dies geschieht über S3-Methoden, die jeder Klasse und/oder Unterklasse zugewiesen sind, wie bei „set_replicate_names“ gezeigt. Ein weiteres Beispiel für den Zugriff, den Export als CSV-Datei und die Darstellung des Totalionenstromchromatogramms (TIC, Total Ion Current) der zur Engine hinzugefügten Dateien ist unten aufgeführt. Alle für eine bestimmte S3-Klasse verfügbaren Methoden sind als Hilfeseiten im R-Paket sowie auf der Referenzseite³³ der StreamFind-Website aufgeführt und dokumentiert.

```
tic <- get_spectra_tic(ms$Analyses)
```

```
data.table::fwrite(tic, "tic.csv")
```

```
tic_plot <- plot_spectra_tic(  
  ms$Analyses,  
  colorBy = "replicates",  
  downsize = 3,  
  levels = 1,  
  interactive = TRUE  
)
```

wobei *get_spectra_tic* eine S3-Methode aus der Klasse *MassSpecAnalyses* ist und *ms\$Analyses* ein Objekt der Klasse *MassSpecAnalyses* ist, auf das über das *\$*-Zeichen von *ms* zugegriffen wird, das ein Objekt der Klasse *MassSpecEngine* ist. Das Objekt *tic* ist eine *data.table*, die zur weiteren Verwendung einfach als CSV gespeichert werden kann. Die Funktion *plot_spectra_tic* erzeugt ein Diagramm, wie in *Abbildung 5* dargestellt. Das Argument *interactive* kann für ein interaktives Diagramm auf *TRUE* gesetzt werden, was bei großen Datenmengen nützlicher ist. Mit der Funktion *orca*³⁴ kann das interaktive Diagramm als PNG-Bild exportiert werden, wie in *Abbildung 5* dargestellt.

³³ <https://odea-project.github.io/StreamFind/reference/index.html>

³⁴ <https://github.com/plotly/orca>




Abbildung 5: Totalionenstromchromatogramme der MS-Daten des NTS-Projekts, die mit der S3-Methode `plot_spectra_tic` der Klasse `MassSpecAnalyses` ermittelt und über die Funktion `orca` exportiert wurden.

Der letzte Aspekt der Plattform ist die Möglichkeit, ein Projekt zu speichern und zu laden. Dieses Framework wurde über das native RDS-Dateiformat³⁵ von R und unter Verwendung einer serialisierten Liste der Projektobjekte implementiert, die zu einer SQLite-Datenbankdatei³⁶ hinzugefügt werden. Die Funktion zum Speichern bzw. Laden von Projekten ist für die Implementierung des Frontends und zur Unterstützung der Benutzer bei der Durchführung retrospektiver Datenanalysen von entscheidender Bedeutung, da ein vergangenes Projekt geöffnet werden kann, um die Datenabfrage und die Queranalyse mit anderen Projekten zu automatisieren. Ein konkretes Beispiel ist die kontinuierliche Kontrolle der Erkennung interner Standards in MS-Daten über NTS-Projekte hinweg, um die Empfindlichkeit des Analysegeräts und die Leistung der chromatografischen Methode zu bewerten.

```
ms$save("nts_project.rds")
```

³⁵ <https://www.rdocumentation.org/packages/base/versions/3.6.2/topics/readRDS>

³⁶ <https://cran.r-project.org/web/packages/RSQLite/vignettes/RSQLite.html>

```
ms_new_obj <- MassSpecAnalyses$new()
```

```
ms_new_obj$load("nts_project.rds")
```

wobei die Methode *save* das Speichern der Engine im Dateiformat *.rds* oder *.sqlite* ermöglicht und die Methode *load* das Laden eines zuvor gespeicherten Projekts ermöglicht.

2.3. Arbeitspaket 3 – streamFind Frontend

2.3.1. Einleitung

Das Frontend für das StreamFind R-Paket wurde als Prototypversion mit KNIME und als Shiny App entwickelt. Die Shiny App verwendet ebenfalls die Programmiersprache R, was die Wartung und Weiterentwicklung nach dem Projekt vereinfacht, da Backend-Entwickler in der Regel mit der Programmiersprache R vertraut sind. Im Gegensatz dazu hätte eine Anwendung mit JavaScript und React als Single Page Application (SPA) den Nachteil, dass sie nach Projektende zusätzliche Komplexität bei der Entwicklung und Wartung verursachen würde. Die Shiny App wurde mit einem modularen Ansatz entwickelt, um analytische Workflows zu vereinfachen und zugänglicher zu machen. Die Anwendung bietet eine vollständige Umgebung vom Datenimport bis zur Ergebnisvisualisierung und ermöglicht die Durchführung komplexer Analysen. Die Anwendung folgt einem logischen Workflow, der den Benutzer durch den Analyseprozess führt:

- **Project** – Einrichtung und Konfiguration von Projektmetadaten
- **Analyses** – Laden und Organisation von Daten
- **Explorer** – Visualisierung der Rohdaten
- **Workflow** – Erstellung und Ausführung von Verarbeitungspipelines
- **Results** – Darstellung und Interaktion mit verarbeiteten Daten
- **Audit Trail** – Nachverfolgung von Operationen
- **Configuration** – Anpassung der Anwendungseinstellungen

Die Anwendung folgt einem modularen Designmuster unter Verwendung des S3-Methodensystems, wodurch Verantwortlichkeiten getrennt und die Wartbarkeit verbessert werden. Die Kernanwendung wird in *app_server.R* und *app_ui.R* initialisiert, wo die Hauptstruktur und reaktive Abhängigkeiten (d. h. *ReactiveValues*, die für die Zustandsverwaltung verwendet werden) eingerichtet werden. Für jede Hauptkomponente wurden spezielle Module mit eigener Benutzeroberfläche und Serverlogik implementiert. Dieser Ansatz ermöglicht eine bessere

Codeorganisation und erleichtert die Erweiterung der Anwendung. Neue Funktionen können hinzugefügt werden, ohne die bestehenden Funktionen zu beeinträchtigen. Die Anwendung enthält mehrere Hilfsfunktionen, die allgemeine Aufgaben wie Dateisystemoperationen und Benachrichtigungsmanagement übernehmen.




Abbildung 6: Startseite der StreamFind Shiny App, auf der der Benutzer eine datentypspezifische Engine auswählt, eine bereits vorhandene Engine oder ein Demoprojekt öffnen kann, das NTS auf Basis von MS-Daten vorstellt.

2.3.2. Projekt- und Analysemanagement

Die erste Seite der StreamFind-App ist das Projektmanagement (siehe Abbildung 7 links). Hier kann der Benutzer das Arbeitsverzeichnis definieren und die Metadaten (d. h. Autor, Beschreibung, Datum, Probenort usw.) für ein bestimmtes Projekt eingeben. Damit werden die Metadaten des Backends definiert. Die zweite Seite ist das Analysemanagement (siehe Abbildung 7 rechts), wo der Benutzer Analysedateien laden kann, die für den Datentyp der Engine angegeben sind (z. B. mzML für MS-Daten), und wo er Namen für die Probenreplikate und die zugehörigen Blanks hinzufügen kann. Im Wesentlichen definiert die Tabelle die genauen Analysen der Analysenklasse des Backends.




Abbildung 7: Grafische Benutzeroberflächen für das Projektmanagement (links) und die Analyseverwaltung (rechts) der StreamFind-App.

2.3.3. Workflow-Assembly

Auf der dritten Seite kann ein Datenverarbeitungs-Workflow zusammengestellt werden. Der Benutzer kann einen Datenverarbeitungsschritt aus einer kuratierten Liste von speziellen Datenverarbeitungsmethoden auswählen (d. h., alle mit dem Typ MassSpec definierten ProcessingStep-Klassen stehen für die Zusammenstellung eines MS-Datenverarbeitungs-Workflows zur Verfügung) und ihn zum Workflow hinzufügen (Abbildung 8, linke Spalte unten). Der Workflow ist dann eine Liste von Verarbeitungsschritten, die per Drag-and-Drop angeordnet werden können. Auf der Serverseite der Workflow-Seite werden die Abhängigkeiten und Anforderungen jedes Verarbeitungsschritts überprüft, um den Benutzer bei der Erstellung eines gültigen Datenverarbeitungs-Workflows zu unterstützen. In der rechten Spalte von Abbildung 8 sind die Details eines bestimmten Schritts beispielhaft dargestellt. Der Benutzer kann sowohl in der App als auch über einen Hyperlink zur Online-Referenzseite auf die Dokumentation zugreifen und die einzelnen Parameter des ausgewählten Verarbeitungsschritts ändern. Die grafische Benutzeroberfläche ist so entwickelt, dass neue Datenverarbeitungsschritte, die zum StreamFind R-Paket hinzugefügt werden, keine Änderungen am UI-Code erfordern, da die grafischen Elemente gemäß der generischen ProcessingStep-Klasse gerendert werden und alle untergeordneten Klassen spezifischer Verarbeitungsschritte der generischen Struktur folgen müssen. Im Backend wird die Workflow-Klasse der Engine durch die vom Benutzer erstellte Liste der Verarbeitungsschritte definiert. Wenn der Benutzer den Workflow über die grafische Benutzeroberfläche anwendet, wird jeder Fehler als informative Benachrichtigung angezeigt, die den Benutzer über das Problem informiert, damit er es beheben kann.




Abbildung 8: Grafische Benutzeroberfläche zum Zusammenstellen von Datenverarbeitungs-Workflows (linke Spalte), einschließlich wiederverwendbarem Spezial-Viewer zum Anpassen der spezifischen Parameter eines bestimmten Datenverarbeitungsschritts (rechte Spalte unten) und Links zur Dokumentation, sowohl in der App als auch mit Verweis auf die Online-Seite (rechte Spalten oben).

2.3.4. Modulare grafische und logische Darstellung der Ergebnisse

Die Ergebnisseite dient zur Anzeige der Objekte der Unterklasse Results, die durch den Datenverarbeitungs-Workflow generiert wurden. Über das Shiny Modules-Framework wird ein modularer Ansatz verwendet, der als S3-Methoden jeder untergeordneten Results-Klasse implementiert ist, um die Benutzeroberfläche dynamisch auf der Grundlage der verfügbaren Ergebnisobjekte zu rendern. Dies ermöglicht die Entwicklung spezifischer grafischer Oberflächen für die Ergebnisse, die von der Hauptanwendung StreamFind App entkoppelt sind, was die Wartung und Weiterentwicklung (d. h. die Entwicklung neuer untergeordneter Ergebnis-Klassen aus neuen Datenverarbeitungsmethoden und/oder -engines) erheblich vereinfacht. Die Ergebnisse werden dynamisch mit der tabPanel-Funktion aus dem Shiny-Paket gerendert, die für jede Ergebnisklasse einen Tab generiert. In Abbildung 9 wird die untergeordnete Klasse NTS-Ergebnisse als Beispiel gezeigt. In diesem Fall wird die grafische Oberfläche für die NTS-Klasse ebenfalls als Tab für jeden Abschnitt der Ergebnisse (d. h. Übersicht, Merkmal, Gruppen, interne Standards) gerendert.

2.3.5. Berichts- und Audit-Trail-Seiten

Seite 24 von 54




Abbildung 10: Grafische Benutzeroberfläche für Audit-Trail (rechts) und Rendering vorgefertigter Quarto-Dokumente aus Ergebnissen (links), wodurch die Erstellung interaktiver Berichte und Dashboards ermöglicht wird.

2.4. Arbeitspaket 4 – Schnittstellen

Eine wesentliche Funktionalität von StreamFind ist, dass es die Zusammenstellung, Reproduzierbarkeit und Automatisierung von Datenverarbeitungs-Workflows ermöglicht. Ein wichtiger Aspekt ist daher die Schnittstelle zwischen den Verarbeitungsschritten innerhalb eines Workflows. In StreamFind verfügt ein Verarbeitungsschritt über eine eigene generische Klasse (d. h. die S3 Klasse `ProcessingStep`), die die Struktur für alle verfügbaren bzw. implementierten Verarbeitungsmethoden harmonisiert. In *Abbildung 11* wird die Struktur anhand der JSON-Darstellung veranschaulicht und erläutert, die die Klassenstruktur nachahmt. Die Struktur ist in drei Hauptteile unterteilt. Der erste Teil, der `data_type`, `method`, `required`, `algorithm`, `input`, `output` und `number_permitted` umfasst, besteht aus Einträgen, die vom Backend von StreamFind zum Aufbau und zur Validierung eines Datenverarbeitungs-Workflows verwendet werden. Der zweite Teil ist eine flexible Liste von Parametern, die die Implementierungsbedingungen des spezifischen Algorithmus enthält. Der dritte Teil schließlich bezieht sich auf `version`, `software`, `developer`, `contact`, `link` und `doi`, die Informationen über die Herkunft des Algorithmus sowie Quellen für weitere Informationen enthalten, um die Benutzer bei der Implementierung zu unterstützen. Dies fördert auch ein recht aktives Bewusstsein und Engagement der Benutzer gegenüber den Entwicklern eines bestimmten Algorithmus. Zudem wird Transparenz hinsichtlich der häufig auftretenden Black Box geschaffen, da den Nutzern ermöglicht wird, sich darüber im Klaren zu sein, von wem welche Algorithmen stammen. Die Liste der in StreamFind verfügbaren Methoden wird kontinuierlich erweitert und kann auf der Referenzseite³⁷ der StreamFind-Website eingesehen werden. In StreamFind ist es auch möglich, benutzerdefinierte Methoden oder Algorithmen für eine bereits vorhandene Verarbeitungsmethode in einer lokalen Installation zu

³⁷ <https://odea-project.github.io/StreamFind/reference/index.html#data-processing-s->

verwenden. Benutzer und Entwickler können den Konstruktor und die Methode der untergeordneten Klasse erstellen. Nach dem Laden in eine Arbeitsumgebung wird diese sowohl in der StreamFind-App aufgeführt als auch über Skripte zur Verwendung verfügbar gemacht.




Abbildung 11: Umstrukturierte ProcessingStep-Klasse und Beispiel für die native Verarbeitungsmethode StreamFind zur Annotation von Isotopen und Addukten in NTS, bei der die Methode FindFeatures zuerst in einem Workflow hinzugefügt werden muss und nur eine Einheit zulässig ist. Darüber hinaus müssen die Eingabe und Ausgabe des Verarbeitungsschritts ein MassSpecResults_NonTargetAnalysis sein, das der Strukturkonformität über die validate_object S3-Methode entspricht.

In StreamFind ist ein Datenverarbeitungs-Workflow im Wesentlichen eine Liste von Objekten der S3 Klasse ProcessingStep und wird ebenfalls als S3-Klasse mit dem Namen Workflow implementiert, wie in *Abbildung 12* dargestellt. Die Workflow-Klasse gewährleistet die Konformität der Liste der Verarbeitungsschritte, einschließlich der Überprüfung, ob die Ausgabe und die Eingabe übereinstimmen oder verfügbar sind und ob die erforderlichen vorangehenden Verarbeitungsmethoden im Workflow implementiert sind. Ein konkretes Beispiel ist die Methode GroupFeatures, die erfordert, dass Features verfügbar sind, weshalb die Methode FindFeatures eine vorangehende Voraussetzung ist. Zu beachten ist, dass die Methode FindFeatures aus MS-Rohdaten eine untergeordnete Klasse MassSpecResults_NonTargetAnalysis Results generiert, die wiederum die Eingabe für die Methode GroupFeatures ist. Sowohl die Klasse Workflow als auch die untergeordneten Klassen von ProcessingStep ermöglichen das Speichern als JSON oder RDS, unterstützen gemeinsame Aktivitäten und reproduzieren den Datenverarbeitungs-Workflow exakt für einen anderen Datensatz. Insgesamt entsprechen die Klassen Workflow und ProcessingStep den FAIR-Prinzipien (Findable, Accessible, Interoperable, Reusable – auffindbar, zugänglich, interoperabel und wiederverwendbar).




Abbildung 12: Workflow für die NTS-Projektdemonstration als zusammengefasste JSON-Zeichenfolge, einschließlich der geordneten Liste der untergeordneten Objekte der Klasse ProcessingStep.

Die Verarbeitung von MS-Daten ist aufgrund der Größe der Datensätze sowie der Größe der generierten Ergebnisse rechenintensiv. Beispielsweise beträgt die Rohdatenmenge des in *Tabelle 2* aufgeführten Projekts etwa 6 GB mit über 128.000 Spektren. Das Einlesen der Spektraldaten für die Durchführung der Methode FindFeatures ist daher sehr speicher- und rechenintensiv. Andere Methoden (z. B. FillFeatures, CalculateFeaturesQuality, LoadFeaturesMS1 und LoadFeatureMS2) erfordern die Extraktion von Teilen der originären Spektraldaten, die mit dem Masse-zu-Ladungs-Verhältnis und den Retentionszeitbereichen jedes Features übereinstimmen, was ebenfalls hohe Anforderungen an Speicher und Rechenleistung stellt. Diese Methoden sind bereits effizient in C++ implementiert und werden über Rcpp verwendet, erfordern jedoch immer noch Verarbeitungszeit, was die Performanz verringert, wenn beispielsweise die Parameter einer nachgeschalteten Verarbeitungsmethode iteriert und optimiert werden. Daher wurde in StreamFind ein Caching-System implementiert, mit dem die Ergebnisse (*Tabelle 1*) zwischen den einzelnen Verarbeitungsschritten gespeichert und geladen werden können, wenn sich beim Aufruf nichts ändert, wodurch eine erneute Verarbeitung von Grund auf vermieden wird. Der Prozess wird durch die Erkennung des Caching-Modus in den R-Optionen automatisiert, wodurch manuelle Eingriffe seitens des Benutzers vermieden werden. Der Caching-Modus kann mit den options(„StreamFind_cache_mode“ = „rds“) oder options(„StreamFind_cache_mode“ = „sqlite“) eingestellt werden, um die Ergebnisse zwischen den Verarbeitungsmethoden als RDS bzw. SQLite zu speichern.

2.5. Arbeitspaket 5 – Integration Basis-Workflow

Die grundlegenden NTS-Verarbeitungsmethoden, die in das StreamFind R-Paket integriert wurden, sind in *Tabelle 3* aufgeführt. Für alle grundlegenden Verarbeitungsmethoden wurde innerhalb von StreamFind ein nativer Algorithmus entwickelt, um die Verwendung ohne Abhängigkeiten von externer Software oder anderen R-Paketen zu erleichtern. Eine zusätzliche Verarbeitungsmethode namens `CalculateFeaturesQuality` wurde entwickelt, um fehlende Deskriptoren für Features in externen Feature-Find-Algorithmen zu vervollständigen. Dies bietet dem Benutzer mehr Parameter, um sowohl falsch-negative als auch falsch-positive Ergebnisse während des Datenverarbeitungsworkflows zu reduzieren und gleichzeitig die Zuverlässigkeit der Ergebnisse zu erhöhen, da auf diese Weise mehr Informationen zu jedem Feature zur Verfügung stehen.

Tabelle 3: Liste mit integrierten Algorithmen für grundlegende NTS-Verarbeitungsmethoden.

Verarbeitungsverfahren	Algorithmus	Kommentar
FindFeatures	OpenMS ³⁸	Integriert über patRoön und erfordert externe Software
	XCMS ³⁹	Integriert über patRoön
	KPIC2 ⁴⁰	Integriert über patRoön
	StreamFind	Entwickelt innerhalb von StreamFind
CalculateFeaturesQuality	StreamFind	Entwickelt innerhalb von StreamFind
AnnotateFeatures	StreamFind	Entwickelt innerhalb von StreamFind
GroupFeatures	OpenMS	Integriert über patRoön und erfordert externe Software
	XCMS	Integriert über patRoön
	StreamFind	Entwickelt innerhalb von StreamFind
FilterFeatures	StreamFind	Entwickelt innerhalb von StreamFind
	patRoön ⁴¹	Direkte Integration des R-Pakets
FindInternalStandards	StreamFind	Entwickelt innerhalb von StreamFind
SuspectScreening	StreamFind	Entwickelt innerhalb von StreamFind
	patRoön	Direkte Integration des R-Pakets
	ForIdent ⁴²	Export der Funktionsliste zum Hochladen auf die Plattform

³⁸ <https://openms.de/>

³⁹ <https://www.bioconductor.org/packages/release/bioc/html/xcms.html>

⁴⁰ <https://github.com/hcji/KPIC2>

⁴¹ <https://github.com/rickhelmus/patRoön>

⁴² <https://www.for-ident.org/>

Der StreamFind-Algorithmus zum Finden von Features basiert auf einem derivativen Ansatz, der sehr effizient ist und Vorteile gegenüber anderen Alternativen aufweist. In *Abbildung 13* zeigen wir die Kombination von FindFeatures und FindInternalStandards unter Verwendung von Algorithmen aus StreamFind für beide. In FindInternalStandards wurde außerdem eine Qualitätsprüfung der den Proben zudotierten internen Standards hinzugefügt, um die Bewertung der Systemleistung, die nachgelagerte Datenkorrektur und die retrospektive Datenanalyse zu unterstützen. Die Qualitätsbewertung wird im NTS-Artikel auf der StreamFind-Webseite demonstriert.⁴³




Abbildung 13: Features, die den internen Standards entsprechen, wie sie von den nativen StreamFind-Algorithmen ermittelt werden, einschließlich der Überlagerung der detaillierten Liste von Qualitätsparametern, die mit CalculateFeaturesQuality berechnet oder bei Verwendung des StreamFind-Algorithmus direkt von FindFeatures geliefert werden können.

Bei der Verwendung von hochauflösender MS für NTS wird das Vorhandensein natürlicher schwerer Isotope (z. B. ^{13}C , ^{15}N , ^{34}S , ^{18}O) von Chemikalien in einer bestimmten Probe als Features als falsch-positives Ergebnis angesehen. Dies liegt daran, dass die schwereren Isotope Teil einer Verbindung sind, die immer durch die häufigeren Isotop-Features (z. B. ^{12}C , ^{14}N , ^{32}S und ^{16}O) repräsentiert wird. Andererseits kann die relative Intensität der schwereren Isotope im Vergleich zu dem häufigeren Isotop entscheidende Informationen zur Identifizierung der chemischen Formel liefern. Die Gleichung 1 zeigt beispielsweise, wie sich die Anzahl der Kohlenstoffatome aus dem Verhältnis zwischen den Intensitäten von ^{12}C und ^{13}C ableiten lässt.

⁴³ https://odea-project.github.io/StreamFind/articles/demo_nts.html

$$N = \frac{100 \times \text{Intensität of } [M+1]}{1.1 \times \text{Intensität of } M}$$

Gleichung 1

wobei N die Anzahl der Elemente, $[M+1]$ das erste Isotop (z. B. ^{13}C) und M das Molekölion (z. B. ^{12}C) ist.

Bei Vorhandensein von Halogenen (z. B. Cl und Br) kann ihr spezifisches Isotopenprofil (Abbildung 14) direkte Hinweise auf die Formelzuordnung zu einem bestimmten Feature geben und so die Priorisierung unterstützen. Ein weiterer Aspekt in Bezug auf die Isotopenzuordnung ist, dass die $M+2$ -Isotopenspur häufiger vorkommt als die $M+1$ -Isotopenspur, so dass M und $M+2$ oft die einzigen sichtbaren Isotopenspuren sind, was dazu führt, dass $M+2$ in der verfügbaren Software als eigenständiges Feature erscheint und daher als eine andere Verbindung angesehen wird.




Abbildung 14: Isotopenprofil von Diclofenac ($\text{C}_{14}\text{H}_{11}\text{Cl}_2\text{NO}_2$) auf der linken Seite und dem Pestizid Profenofos ($\text{C}_{11}\text{H}_{15}\text{BrClO}_3\text{PS}$) auf der rechten Seite, wobei die Spur für $M+2$ häufiger ist als die für $M+1$, was ein charakteristisches Merkmal für halogenierte organische Verbindungen ist.

Um diesen Herausforderungen zu begegnen, wurde ein Algorithmus in C++ entwickelt, der Folgendes berücksichtigt:

- Abwesenheit von $M+1$, was Lücken innerhalb einer Isotopenkette erlaubt;
- Validierung der Intensität bei der Zuordnung auf der Grundlage der natürlichen Häufigkeit des Elements mit der besten Übereinstimmung durch Massendefekt;
- Schätzung der Anzahl der Kohlenstoffe auf der Grundlage des Verhältnisses zwischen ^{13}C und ^{12}C ;

- Clustering von isotopischen Patterns für jede Analyse und nicht über Analyse-Replikate hinweg, wie es in einigen verfügbaren Software-Lösungen angewandt wird, wodurch die verzerrten Intensitätsvergleiche abgeschwächt werden.

Der C++-Algorithmus wurde anschließend über das Paket Rcpp in die Plattform integriert und eine spezielle Methode namens AnnotateFeatures implementiert. Die Ergebnisse sind in Abbildung 15 für ausgewählte Substanzen dargestellt.




Abbildung 15: Annotierte Isotope für die internen Standards Diuron-D6 (halogeniert mit Cl) und Carbamazepin-D10 (nicht halogeniert) auf der linken Seite und auf der rechten Seite die annotierten Isotope des internen Standards Diclofenac-D4 und Diclofenac, die in realem Abwasser gefunden wurden, wobei aufgrund der geringeren Intensität nur die M und M+2 sichtbar waren, aber effektiv als Teil derselben Verbindung annotiert wurden.

Ein wichtiger Aspekt von NTS ist die Identifizierung von Chemikalien, die häufig anhand einer Liste von Kandidaten mit erwarteter Masse, Retentionszeit und MS²-Spektren durchgeführt wird. MS²-Spektren bestehen aus Massenfragmenten eines bestimmten Ions, die durch massenabhängige Erfassung (DDA, Data Dependant Acquisition) isoliert wurden, oder aus Massenfragmenten aus einem Massenbereich in der Datenunabhängigen Erfassung (DIA, Data Independant Acquisition), die zur Erhöhung der Identifizierungssicherheit verwendet werden können. Die Extraktion von MS²-Spektren für jedes Feature entweder in DDA oder DIA wurde als Verarbeitungsschritt in StreamFind implementiert. Die Verarbeitungsmethode SuspectScreening

kann dann verwendet werden, um mögliche Kandidaten einem unbekannten Feature zuzuordnen, wodurch eine Identifizierungskategorie entsteht, die auf der Rangfolge von Schymanski et al.⁴⁴ basiert, wie in *Abbildung 16* dargestellt, wobei die Identifizierung von Sulfamethoxazol und Candesartan hervorgehoben wird, die beide mit Kategorie 1 identifiziert wurden.




Abbildung 16: Übersicht über die bei der Verdachtsprüfung identifizierten Chemikalien der Kategorie 1, wobei Sulfamethoxazol und Candesartan, die beide in realen Abwässern gefunden wurden, hervorgehoben sind. Das obere Diagramm zeigt das extrahierte Ionenstromchromatogramm mit einer detaillierten Beschreibung des entsprechenden Features, wobei zu beachten ist, dass keine Qualitätsparameter verfügbar sind, da für die Feature-Suche ein anderer Algorithmus verwendet wurde, was zu fehlenden Informationen geführt hat. Das untere Diagramm vergleicht das MS²-Spektrum der Abwasser-Features (oben) mit dem MS²-Spektrum der Referenzstandards für Sulfamethoxazol und Candesartan zur visuellen Beurteilung der Spektralübereinstimmung.

2.6. Arbeitspaket 6 – Erweiterung

2.6.1. Einleitung

Die Erweiterung von StreamFind erfolgte durch die Entwicklung und Integration fortschrittlicher Algorithmen zur Ergänzung der NTS-Datenverarbeitung, wodurch die Fähigkeiten zur Datenkorrektur, Analyse und Identifizierung von Chemikalien im Wasserkreislauf verbessert wurden. Der NTS-Workflow wurde durch die Entwicklung von Algorithmen zur Korrektur der

⁴⁴ Schymanski, E. L., Jeon, J., Gulde, R., Fenner, K., Ruff, M., Singer, H. P., & Hollender, J. (2014). Identifying Small Molecules via High Resolution Mass Spectrometry: Communicating Confidence. *Environmental Science & Technology*, 48(4), 2097–2098. <https://doi.org/10.1021/es5002105>

Matrixunterdrückung (CorrectionMatrixSuppression) und zur Durchführung von Fold-Change-Analysen verbessert. Zusätzlich wurde ein Algorithmus zur Lückenfüllung entwickelt, um falsch-negative Ergebnisse bei der Feature-Extraktion zu reduzieren (FillFeatures). Darüber hinaus wurden Verarbeitungsschritte zur Identifizierung von Chemikalien in NTS durch In-silico-Fragmentierung in StreamFind integriert (GenerateCompounds), um chemische Umwandlungsprodukte zu identifizieren, die in der Probe oder dem Probensatz auftreten (GenerateTransformationProducts). Eine Liste der relevantesten fortschrittlichen Algorithmen, die in StreamFind entwickelt bzw. integriert wurden, ist in *Tabelle 4* aufgeführt.

Tabelle 4: Liste mit integrierten Algorithmen für fortgeschrittene NTS-Verarbeitungsmethoden.

Verarbeitungsverfahren	Algorithmus	Kommentar
CorrectionMatrixSuppression	TiChri ⁴⁵	Adaptiert aus der wissenschaftlichen Veröffentlichung
Fold-Change-Analyse	als Plot ⁴⁶	Adaptiert aus der wissenschaftlichen Veröffentlichung
FillFeatures	StreamFind	Entwickelt innerhalb von StreamFind
GenerateCompounds	MetFrag ⁴⁷	Integriert über patRoön; erfordert externe Software
GenerateTransformationProducts	CTS ⁴⁸	Integriert über patRoön; erfordert externe Software
	BioTransformer ⁴⁹	Integriert über patRoön; erfordert externe Software

2.6.2. Algorithmus zur Korrektur der Matrixunterdrückung

Ein wichtiger Aspekt der NTS ist der Vergleich von Proben, um den Verbleib von Chemikalien in einem natürlichen Wasserkörper oder durch eine Reihe von Prozessen wie Abwasserbehandlung oder Fermentation zu bewerten. Häufig unterscheidet sich die Matrix (d. h. die Anzahl der

⁴⁵ Tisler, S., Pattison, D. I., & Christensen, J. H. (2021). Correction of Matrix Effects for Reliable Non-target Screening LC–ESI–MS Analysis of Wastewater. *Analytical Chemistry*, 93(24), 8432–8441. <https://doi.org/10.1021/acs.analchem.1c00357>

⁴⁶ Bader, T., Schulz, W., Kümmerer, K., & Winzenbacher, R. (2017). LC-HRMS Data Processing Strategy for Reliable Sample Comparison Exemplified by the Assessment of Water Treatment Processes. *Analytical Chemistry*, 89(24), 13219–13226. <https://doi.org/10.1021/acs.analchem.7b03037>

⁴⁷ Ruttkies, C., Schymanski, E. L., Wolf, S., Hollender, J., & Neumann, S. (2016). MetFrag relaunched: Incorporating strategies beyond in silico fragmentation. *Journal of Cheminformatics*, 8(1). <https://doi.org/10.1186/s13321-016-0115-9>

⁴⁸ <https://qed.epa.gov/cts/>

⁴⁹ <https://biotransformer.ca/>

nachweisbaren Substanzen) von Probe zu Probe erheblich, was einen realistischen Vergleich aufgrund der Ionensuppression (d. h. der Ionisationskonkurrenz zwischen Substanzen zur Erzeugung von Ionen, $[M+H]^+$ oder $[M-H]^-$) erschwert. Vor diesem Hintergrund haben Tisler et al. (2021) ein Konzept zur Korrektur der Matrixunterdrückung vorgestellt, das den Vergleich von Proben mit unterschiedlichen Matrixniveaus realistischer macht. Im Rahmen von AP 6 haben wir einen Algorithmus entwickelt, der auf dem vorgeschlagenen Konzept basiert. Ein Beispiel für Unterschiede in der Matrixunterdrückung zwischen Blindproben sowie Zu- und Ablaufproben einer Abwasserbehandlungsanlage mit Ozonzugabe ist in Abbildung 17 dargestellt. Der Algorithmus berücksichtigt den TIC und optional dotierte interne Standards zur Korrektur extrahierter Features aus einem grundlegenden NTS-Workflow. Nach der Korrektur ist das Intensitätsprofil der dotierten internen Standardsignale in Abbildung 17d vergleichbar mit dem Intensitätsprofil der gleichen Signale ohne Korrektur (Abbildung 17c). Es ist zu beachten, dass die internen Standards in allen Proben mit der gleichen Konzentration dotiert wurden, so dass für alle Proben die gleiche Intensität erwartet wird. Bei der Durchführung von Trendanalysen oder Fold-Change-Analysen (d. h. Änderungen der Häufigkeit von Chemikalien in den Proben) ist die Korrektur der Matrixunterdrückung daher unerlässlich, um genaue Ergebnisse zu erhalten.




Abbildung 17: Matrixunterdrückungsprofil von Leerwertproben sowie dem Zulauf und Ablauf einer Abwasserbehandlungsstufe mit Ozonung (a und b für positive bzw. negative Ionisationsmodi). Intensitätsprofil von dotierten internen Standards (d. h. Isoproturon-D6, Diuron-D6 und Metoprolol-D7) und Spurenstoffen (d. h. 1H-Benzotriazol and Metoprolol), die im Abwasser ohne (c) und mit (d) Anwendung der Matrixkorrektur gefunden wurden. Es ist zu beachten, dass die internen Standards in allen Proben in der gleichen Konzentration dotiert wurden.

2.6.3. Algorithmus für Fold-Change-Analyse

Bei NTS wird ein möglicher Abbau oder Transformationsprozesse von Chemikalien hauptsächlich anhand von Intensitätsänderungen zwischen den Proben beurteilt. Häufig wird die Anzahl der in verschiedenen Proben gefundenen Features verwendet, um die Anzahl der nachgewiesenen Chemikalien zu vergleichen (Abbildung 18). Es ist jedoch schwierig, aus der Anzahl von Features auf eine Auf- oder Abwärtsregulation (d. h. die Bildung oder den Abbau von Chemikalien) zu schließen. Vor diesem Hintergrund haben Bader et al. (2017) ein Konzept

vorgestellt, bei dem Kategorien (d. h. Removed, Decrease, Constant, Increase, Formation) für die Intensitätsänderung zwischen zwei Proben angegeben werden. Ein relevanter Aspekt dieses Konzepts ist die Verwendung von Wiederholungsmessungen, um die Signifikanz der Intensitätsänderung zu erhöhen und die Kategorisierung robuster zu machen. Wir haben darauf aufbauend einen Algorithmus entwickelt, der auf dem vorgeschlagenen Konzept von Bader et al. (2017) basiert, um es StreamFind-Benutzern zu ermöglichen, Fold-Change-Analysen mit höherer Zuverlässigkeit durchzuführen. Abbildung 19 zeigt die Anwendung und Auswirkung des Algorithmus für den Schritt der Abwasserbehandlung mittels Ozonisierung. Es wird eine deutliche Entfernung von Features (d. h. Substanzen) beobachtet, aber auch die Bildung von Transformationsprodukten. Mit diesem Verarbeitungsschritt kann eine weitere Priorisierung vorgenommen werden, wenn der Schwerpunkt beispielsweise auf der Identifizierung der Transformationsprodukte liegt. Die Parameter der Fold-Change-Analyse ermöglichen es dem Benutzer, die Intensitätsschwellen für die Kategorisierung sowie die zu vergleichenden Probenpaare zu definieren.




Abbildung 18: Gesamtzahl der Features, die in den Blindproben und in den Proben aus dem Zu- und Abfluss der Abwasser-Ozonbehandlung vor (a) und nach (b) der Anwendung der Filterverarbeitungsschritte gefunden wurden.




Abbildung 19: Fold-Change-Analyse zwischen Zufluss und Abfluss der Abwasser-Ozonbehandlung für positive und negative Ionisationsmodi unter Verwendung des Algorithmus nach Bader et al. (2017).

2.6.4. Integration von MetFrag zur in-silico-Identifizierung von Chemikalien

In den NTS-Basis-Workflow von AP 5 wurde ein Verarbeitungsschritt für das Suspect-Screening integriert, um die Identifizierung von Chemikalien auf der Grundlage einer kuratierten Datenbank zu ermöglichen, die die erforderlichen Informationen enthält (d. h. Masse, Retentionszeit und optional Fragmentierungsmuster zur Erhöhung der Identifikationssicherheit). Für die Erfassung von Retentionszeitwerten und Fragmentierungsmustern ist jedoch ein Referenzstandard erforderlich (d. h. der Anwender muss den Referenzstandard kaufen und mit derselben Methode messen). Vor diesem Hintergrund wurde die Software MetFrag über das bestehende R-Paket patRoön⁵⁰ in StreamFind integriert. MetFrag ermöglicht die in-silico-Fragmentierung, d. h. die Erzeugung eines simulierten Fragmentierungsmusters für eine bestimmte chemische Struktur, und die anschließende Identifizierung durch den Vergleich des experimentellen Fragmentierungsmusters eines bestimmten Features mit dem simulierten Fragmentierungsmuster. Die simulierten Fragmentierungsmuster werden anhand von Verbindungen erzeugt, die in öffentlichen Datenbanken wie CompTox und PubChem aufgeführt

⁵⁰ Helmus, R., ter Laak, T. L., van Wezel, A. P., de Voogt, P., & Schymanski, E. L. (2021). patRoön: open source software platform for environmental mass spectrometry based non-target screening. *Journal of Cheminformatics*, 13(1), 1–25. <https://doi.org/10.1186/s13321-020-00477-w>

sind. In StreamFind wurde ein Verarbeitungsschritt implementiert, der es Benutzern ermöglicht, auf der Grundlage größerer Datenbanken als beim Suspect-Screening-Verarbeitungsschritt Kandidatenverbindungen zu generieren. Die auf diese Weise identifizierten Stoffkandidaten werden dann als Eigenschaft jedes Features hinzugefügt.

2.6.5. Integration der Erzeugung von Transformationsprodukten

Chemische Umwandlungen kommen in der Umwelt natürlich vor, werden aber auch durch Behandlungsprozesse ausgelöst. So ist beispielsweise bekannt, dass die Ozonisierung von Abwasser die Bildung oxidativer Umwandlungsprodukte auslöst. Daher haben wir in StreamFind Verarbeitungsmethoden integriert, mit denen der Benutzer Transformationsprodukte von Kandidaten (z. B. bereits in einem Projekt identifizierte Verbindungen) generieren und anschließend deren Vorhandensein in der Feature-Liste bewerten kann. Ein weiterer Verarbeitungsschritt wurde implementiert, um die Kosinusähnlichkeit der MS²-Spektren zwischen Ausgangsstoffen und Umwandlungsprodukten zu berechnen, wodurch die Zuverlässigkeit der Überprüfung erhöht werden kann. In Abbildung 20 ist die Erkennung und Überprüfung eines oxidativen Umwandlungsprodukts des Pestizids Triethylphosphat mittels StreamFind für eine lange Probenkampagne von Oberflächenwasser dargestellt.




Abbildung 20: Oxidatives Transformationsprodukt von Triethylphosphat, das in einer langen Probenreihe von Oberflächenwasser mittels CTS-Integration nachgewiesen und anschließend in StreamFind identifiziert und durch MS2 verifiziert wurde.

2.7. Arbeitspaket 7 – Berichterstellung

Die Berichterstellung wurde als dynamische Darstellung von Markdown-Quarto-Dokumenten⁵¹ implementiert, wodurch die Einbindung von Code-Blöcken ermöglicht wurde, in denen StreamFind-Code zur flexiblen Anzeige von Rohdaten und Ergebnisdaten in verschiedenen Formen (d. h. interaktive Datentabellen und Diagramme) verwendet wird. In der StreamFind-App wurde eine Dashboard-Registerkarte für die Darstellung einer vordefinierten Quarto-Vorlagendokumentation auf Basis der Projektdaten implementiert (Abbildung 21). Der Benutzer muss lediglich das Quarto-Markdown-Dokument mit Standardmethoden für die Darstellung oder das Rendern von Datentabellen, die in StreamFind verfügbar sind, vorab ausfüllen. Beim Rendern werden die tatsächlichen Daten dann dynamisch zum Bericht hinzugefügt. Das Quarto-Framework ermöglicht eine Vielzahl von Exportformaten (z. B. PDF, DOCX und interaktive HTML-basierte Dashboards, Dokumente, Folien). Ein Beispiel für die dynamische HTML-Berichterstellung ist in der aktuellen Dokumentation und den Demonstrationsartikeln von StreamFind zu finden, die auf der Webseite⁵² verfügbar sind.




Abbildung 21: Screenshot eines NTS-Berichtsdokuments im HTML-Format, das aus einer vorgefertigten Quarto-Markdown-Datei über die Registerkarte „Bericht“ der StreamFind-App erstellt wurde.

⁵¹ <https://quarto.org/>

⁵² <https://odea-project.github.io/StreamFind/articles/index.html>

2.8. Arbeitspaket 8 – Verbreitung

2.8.1. Einleitung

Die Verbreitung der Ergebnisse aus dem StreamFind-Projekt ist mit Förder- und Austauschaktivitäten sowie dem Erweiterungskonzept für das StreamFind-R-Paket verbunden (d. h. Erweiterung seiner Funktionen durch Hinzufügen neuer Datenverarbeitungsmodule zur Abdeckung anderer Datentypen, Integration neuer Verarbeitungsschritte und Erweiterung bestehender Verarbeitungsschritte um neue Algorithmen, um dieselbe Aufgabe mit einer anderen Strategie auszuführen).

2.8.2. Austauschaktivitäten

Die im Rahmen des Projekts durchgeführten Austauschaktivitäten (d. h. Veröffentlichungen, Vorträge, Workshops und Poster), bei denen das Konzept und die Ergebnisse des streamFind-Projekts vorgestellt und/oder genutzt wurden, sind nachfolgend aufgeführt:

Veröffentlichungen

- Cunha, J. R., Laurito, W., Thoma, S., Kläßen, M. D., Teutenberg, T.; StreamFind: Workflow-Designer zur flexiblen Datenanalyse und Identifizierung von Chemikalien im Wasserkreislauf; Wasserforum, Sonderpublikation zum 15. Langenauer Wasserforum, (2023) S. 51-53
- Kochale, K., Thissen, J., Cunha, R., Lamotte, S., Teutenberg, T., Schmidt, T. C.; Enrichment and quantification of 18 polycyclic aromatic hydrocarbons from intermediates for plastics production by a generic liquid chromatography column switching; Journal of Separation Science (2023) Vol. 46 Issue 14, 2300076
- Cunha, R. Laurito, W., Thoma, S., Kläßen, M. D., Teutenberg T.; StreamFind: Data processing workflow designer; Analytical Science Magazine, Band 1 – 24. 02/2024
- Cunha, R., Thissen, J., Laurito, W., Thoma, S., Kläßen, M. D., Teutenberg T.; StreamFind: Software Tool zur Datenverarbeitung – Flexibler Workflow-Designer für verschiedene Anwendungen; GIT Labor-Fachzeitschrift 4/2024, 32, Wiley-VCH GmbH, Weinheim
- Kochale, K., Lang B., Cunha R., Teutenberg T., Schmidt T. C.; Online coupling of miniaturized HPLC and high-performance thin layer chromatography by a fractionation unit for effect directed analysis; Advances in Sample Preparation, <https://doi.org/10.1016/j.sampre.2024.100102>
- Thissen, J., Kläßen, M. D., Fischer, B., Hacker, M. C., Breitzkreutz, J., Teutenberg, T., Cunha, R.; StreamFind: data processing workflows for qualification and quantification of biopharmaceutical drug products analyzed by size exclusion chromatography coupled to

capillary-enhanced Raman spectroscopy; Anal. Bioanal. Chem. 2025, 417, pp. 4469-4480, DOI: 10.1007/s00216-025-05964-3

- Cunha, R.; Data and Data Processing Standards; In Teutenberg, T. (Ed.), Laboratory of the Future – Building the Digital Transformation; 1. Auflage, September 2025, 17-34, ISBN 978-3-527-35265-4, Wiley-VCH, Weinheim

Präsentationen

- Cunha, J. R.; Overarching concept and framework of streamFind: Flexible data analysis and workflow designer to identify chemicals in the water cycle; Proteomics4Future, 11.11.2022 (online)
- Cunha, J. R.; Overarching concept and framework of streamFind: Flexible data analysis and workflow designer to identify (relevant) chemicals in the water cycle; Ruhr-Rhein-Main-Talks, BfG Koblenz 20.12.2022
- Cunha, R., Türk, J.; Quantification of N-Nitrosamines and Non-target Screening of their precursors during treatment of secondary wastewater effluent with ozone followed by biological post-treatment; Wasser 2023, Augsburg, 16.05.2023
- Cunha, J. R., Laurito, W., Thoma, S., Teutenberg, T., Tuerk, J.; StreamFind, a flexible workflow designer for NTS data analysis in environmental and quality control studies; ICNTS23, Erding, 16.10.2023
- Kochale, K., Cunha, R., Teutenberg, T., Schmidt, T. C.; Development of a column switching for direct online enrichment and separation of polar and nonpolar analytes from aqueous matrices; HPLC 2023, Düsseldorf, 18.-22.06.2023
- Thissen, J., Klassen, Cunha, J.R., Wenig, P., Hacker, M.C., Breitreutz, J., Teutenberg, T., Fischer, B.; Automated data processing of Raman spectra from online coupled size exclusion chromatography to Raman spectroscopy for protein analysis; 51st International Symposium on High Performance Liquid Phase Separations and Related Techniques (HPLC 2023), Düsseldorf, 18. – 22.06.2023
- Cunha, R.; StreamFind: Data processing workflow designer; smartlab.network meeting, Online, 17.04.2024
- Cunha, R.; Harmonizing and processing data with an open-source approach and interoperable framework; Future Labs Live, Basel, Schweiz, 26.06.2024
- Cunha, R.; Data Standards and Non-target Screening (NTS): Why is Data Standardization Essential for NTS?; PINTS24-Workshop, Online, 23.10.2024

- Kochale, K., Cunha R., Teutenberg T., Schmidt T. C.; Entwicklung einer Säulenschaltung zur Anreicherung und Trennung von polaren und unpolaren Analyten aus wässrigen Matrices; Doktorandenseminar des AK Separation Science der GDCh, Hohenroda, 09.01.2024
- Kochale, K., Cunha R., Teutenberg T.; Non-Target-Screening von polaren und unpolaren Verbindungen unter Verwendung einer neuartigen multidimensionalen Methode und der Open-Source-Software StreamFind zur Datenauswertung; MWAS 2024, Mülheim a.d.R., 10.09.2024
- Kochale, K., Cunha R., Teutenberg T., Schmidt T. C.; Development of a column switching for direct online enrichment and separation of polar and nonpolar analytes from aqueous matrices; ISC 2024, Liverpool, UK, 09.10.2024
- Teutenberg, T., Cunha, R., Jochums, M., Kochale, K.; On the road of digital transformation: Building the fully automated and digitalized lab of the future; Analytica conference 2024, München, 09.04.2024
- Teutenberg, T., Cunha, R., Jochums, M., Kochale, K.; Auf dem Weg zur digitalen Transformation: Aufbau eines digitalisierten und vollautomatisierten Labors der Zukunft; Analytica 2024 – Forum Digital Transformation, München, 11.04.2024
- Thissen, J., Kläßen, M., Cunha, R., Wenig, P., Hacker, M.C., Breitzkreutz, J., Teutenberg, T., Fischer, B.; Online coupling of size exclusion chromatography to Raman spectroscopy for the analysis of therapeutic proteins and disaccharides; International Symposium on Hyphenated Techniques in Chromatography and Separation Technology, HTC-18, Leuven, BE, 29.05.2024
- Thissen, J., Cunha, R., Wenig, P., Kläßen, M., Teutenberg, T.; Das Projekt iSoft – Entwicklung einer innovativen Softwarelösung für die Fusion und automatisierte Datenprozessierung von chromatografischen, spektroskopischen und massenspektrometrischen Daten; IUTA Workshop: Datenstandards, Schnittstellen und Konnektivität, Duisburg, 20.02.2024
- Cunha, J. R., Laurito, W., Steffen, T., Kläßen, D. M., Teutenberg, T.; Use Cases for LADS OPC UA and Allotrope Simple Model in StreamFind Workflow Applications; Digital Lab Day, Online, 14.05.2025
- Cunha, J. R., Laurito, W., Steffen, T., Kläßen, D. M., Teutenberg, T.; StreamFind: open Source, agnostic and flexible data processing workflow designer; HPLC25, Brügge, Belgien, 16.06.2025
- Cunha, J. R., Laurito, W., Steffen, T., Kläßen, D. M., Teutenberg, T.; StreamFind: open source, agnostic and interoperable data processing workflows; ICNTS25, Erding, 13.10.2025
- Cunha, R.; StreamFind; from (complex) data to automated, reproducible and interactive reporting; 9. AnalytikTag, Duisburg, 10.11.2025

- Kochale, K., Harikrishnan, S., Cunha, R.; Reliability through prediction: Predictive maintenance for analytical instruments; 9. AnalytikTag, Duisburg, 10.11.2025
- Teutenberg, T., Cunha, R.; Promoting digitalization, automation and sustainability: Use cases for the Open-Source-Software Platform StreamFind; INVITE Science Day 2025, 09.07.2025

Workshops

- Cunha, R.; Das Projekt streamFind – Entwicklung eines flexiblen Open-Source Workflow-Managers für multidimensionale Analysedaten IUTA Workshop Datenstandards, Schnittstellen und Konnektivität; Duisburg, 20.02.2024
- Cunha, R., Teutenberg, T.; Workshop Data Standard meets Communication Standard, November 11, 2025, Duisburg

Posters

- Cunha, R., Thissen, J., Laurito, W., Thoma, S., Kläßen, M. D., Teutenberg T.; StreamFind: Data processing workflow designer for non-target screening and highly hyphenated analytical systems; HTC18, Leuven, Belgien, 28.05.2024
- Thissen, J., Kläßen, M.D., Fischer, B., Teutenberg, T., Cunha, R.; StreamFind: Facilitating identification, quantitation and qualification of different biopharmaceutical products analyzed by applying size exclusion chromatography coupled to capillary-enhanced Raman spectroscopy; ANAKON 2025, Leipzig, 10.03.2025 – 13.03.2025

2.8.3. Extension

StreamFind ist als R-Paket aufgebaut und nutzt das R-Entwicklungsframework, um die Erweiterung zu steuern und zu unterstützen. Die Klassen „ProcessingStep“ und „Workflow“ verfügen über einen integrierten Validierungsprozess, um sicherzustellen, dass neue Verarbeitungsmethoden die Mindestanforderungen für die Verwendung in StreamFind erfüllen. Darüber hinaus wird Roxygen⁵³ in StreamFind verwendet, um die Erstellung von Dokumentationen, einschließlich solcher für neue Verarbeitungsmethoden, zu automatisieren. Dies ermöglicht es Entwicklern, umfassende Dokumentationen zur Unterstützung der Nutzung bereitzustellen. Ein Beispiel⁵⁴ für die Dokumentation ist auf der StreamFind-Website für die native Methode „AnnotateFeatures“ zu finden. Die Vereinfachung der Erweiterung bedeutet, dass Dokumentation und Verarbeitungsmethoden hinzugefügt werden können, ohne die grafische Benutzeroberfläche zu verändern, da das Rendering generisch auf die Klasse „ProcessingStep“

⁵³ <https://roxygen2.r-lib.org/index.html>

⁵⁴ https://odea-project.github.io/StreamFind/reference/MassSpecMethod_AnnotateFeatures_StreamFind.html

und nicht auf deren untergeordnete Klassen angewendet wird. Wie bereits erwähnt, unterstützt StreamFind die Verwendung von C++ und Python für die Datenverarbeitung, sodass Entwickler neben R auch diese Sprachen verwenden können. StreamFind wird auf GitHub gehostet, das für die Versionsverfolgung und die kollaborative Entwicklung genutzt wird. Auf der StreamFind-Webseite werden Beispiele⁵⁵ für die Datenverarbeitung veröffentlicht, um die Nutzung durch eine breitere Öffentlichkeit zu fördern.

3. Zusätzliche Arbeiten außerhalb des ursprünglichen Plans

3.1. Einleitung

Es wurden Anwendungen für die Quantifizierung von Chemikalien auf Basis chromatografischer Daten und für die Identifizierung monoklonaler Antikörper auf Basis von LC-HRMS entwickelt. Darüber hinaus wurden vollständige Frameworks für die Verarbeitung von Raman-Spektroskopiedaten und für die Durchführung von Machine-Learning-Analysen auf Basis tabellarischer Daten entwickelt.

3.2. Quantifizierung von Biopharmazeutika mit LC-UV-Daten

Die Quantifizierung ist ein wesentlicher Datenverarbeitungsprozess für analytische Laboratorien. Vor diesem Hintergrund haben wir Datenverarbeitungsschritte zur Quantifizierung von Chemikalien auf der Basis chromatografischer Daten entwickelt und in StreamFind integriert. Obwohl dieser Datenverarbeitungsprozess ursprünglich nicht im Projektantrag vorgesehen war, wurde seine Relevanz für analytische Labore bei der Implementierung in StreamFind berücksichtigt. Als Demonstrationsanwendung wird die Quantifizierung von Biopharmazeutika auf der Basis von Daten aus der Flüssigkeitschromatografie (LC) gekoppelt mit UV-Detektion verwendet. LC-UV-Daten werden durch Konvertierung von in den meisten Fällen proprietären Herstellerdateien in das Open-Source-Format mzML verfügbar gemacht und dann unter Verwendung der entwickelten C++-Parsing-Funktionen in StreamFind zur Quantifizierung geladen. Die Chromatogramme können dann mit speziellen Visualisierungsmethoden der Chromatogramm-Klasse, einer Unterklasse von Results, wie in Abbildung 22 dargestellt, untersucht werden. Der Workflow besteht aus dem Laden der gewünschten Chromatogramme, des Smoothing (falls erforderlich), der Basislinienkorrektur (falls erforderlich), der Peakerkennung und -integration und schließlich der Quantifizierung auf der Grundlage der integrierten chromatografischen Peaks. Abbildung 23 zeigt die integrierten chromatografischen Peaks mit der dedizierten Methode der Chromatogramm-Klasse. Es ist zu beachten, dass alle Methoden der

⁵⁵ <https://odea-project.github.io/StreamFind/articles/index.html>

untergeordneten Ergebnisklassen dem Anwender über die Klasse MassSpecEngine (R6-Klasse) zur Verfügung stehen, in die eine spezielle Dokumentation integriert wurde, um die Anwendung zu erleichtern und zu leiten. Die Quantifizierung wird der Klasse Chromatograms als Modellobjekt hinzugefügt (z. B. basierend auf linearer Regression). Die Konzentration der Kalibrieranalysen kann als Parameter des ProcessingStep oder als Metadaten der Klasse MassSpecAnalyses hinzugefügt werden. Die Quantifizierung wird dann für chromatografische Peaks von Analysen ohne definierte Konzentration unter Verwendung der Vorhersagemethode des Quantifizierungsmodells durchgeführt. In Abbildung 24 wird die Kalibrierungskurve aus dem Modell basierend auf der dedizierten Methode der Chromatogramm-Klasse dargestellt. In Tabelle 1 sind die Quantifizierungsergebnisse der Demonstrationsanalysen aufgelistet.




Abbildung 22: Chromatogramme, die aus einer mzML-Datei extrahiert wurden (d. h. ein Open-Source-Dateiformat, das durch Konvertierung des proprietären Dateiformats generiert wurde) und LC-HRMS- und LC-UV-Daten enthalten.




Abbildung 23: Chromatografische Peaks für das betreffende Chromatogramm, die in allen Analysen (d. h. sowohl in den Kalibrierungsanalysen als auch in den Analysen zur Quantifizierung) gefunden und integriert wurden.




Abbildung 24: Kalibrierungskurve des linearen Regressionsmodells, das zur Quantifizierung verwendet wurde.

Tabelle 5: Berechnete Konzentrationen für die Qualitätskontrollanalysen und für die Analysen mit unbekannter Konzentration des Biopharmazeutikums.

Analyse	Retentionszeit	Peakfläche	Intensität	Konzentration	Erwartete Konzentration	Wiederfindung
20240815_67_BVCZ_1	342.8	1103.97	222.82	2.56	NA	-
20240815_67_BVCZ_2	343.1	1123.8	225.96	2.61	NA	-
20240815_67_BVCZ_3	343.38	1108.19	223.86	2.57	NA	-
BVCZ Kal 24-3 0.5	345	201.65	42.99	0.44	0.5	88
QC_BVCZ_1608_2_5mgmL_1	342.92	1091.65	219.15	2.53	2.5	101.2
QC_BVCZ_1608_2_5mgmL_2	342.82	1176.24	233.7	2.73	2.5	109.2
QC_BVCZ_1608_2_5mgmL_3	343.15	1114.26	222.39	2.58	2.5	103.2

3.3. Identifizierung intakter monoklonaler Antikörper mittels LC-HRMS

Monoklonale Antikörper werden in der Krebstherapie eingesetzt, da sie in der Lage sind, sich an Krebszellen zu binden und vom körpereigenen Abwehrsystem leichter erkannt und gezielt zerstört werden können. Vor diesem Hintergrund wurde in StreamFind ein Datenverarbeitungs-Workflow für die Entfaltung und Identifizierung (d. h. exakte Massenverifizierung) intakter monoklonaler Antikörper in LC-HRMS-Daten entwickelt. Obwohl dieser Datenverarbeitungs-Workflow ursprünglich nicht im Projektantrag vorgesehen war, wurde seine Relevanz für analytische Labors bei der Implementierung in StreamFind berücksichtigt. Der Workflow beginnt mit der Identifizierung der Elutionszeit des monoklonalen Antikörpers durch Integration des Totalionenstrom-Chromatogramms, wie in Abbildung 25 dargestellt. Der im Quantifizierungsworkflow verwendete Verarbeitungsschritt wird wiederverwendet, jedoch für ein anderes Ziel. Anschließend wurde ein Verarbeitungsschritt zum Laden von Spektren auf der Grundlage der Elutionszeit jedes identifizierten chromatografischen Peaks implementiert, wie in Abbildung 26 dargestellt. Die Entfaltung basiert auf zwei Verarbeitungsschritten: (1) Zuordnung von Ladungen zu jedem Ladungscluster und (2) Massenentfaltung jedes Ladungsclusters. Beispiele für die Ergebnisse der Ladungszuweisung und der Massendekonvolution sind in Abbildung 27 dargestellt. Die Masse der verschiedenen Glykosylierungsmuster des monoklonalen Antikörpers kann durch Anwendung eines Verarbeitungsschritts zur Peak-Erkennung auf die massenspektrometrischen Daten abgerufen werden, wie in Abbildung 28 dargestellt. Mit diesem Workflow zur Datenverarbeitung wird eine automatisierte Erkennung und Bewertung

monoklonaler Antikörper ermöglicht, um die Qualitätskontrolle von Biopharmazeutika zu unterstützen.




Abbildung 25: Integriertes Totalionenstrom-Chromatogramm (TIC) aus einer Reihe von Analysen.




Abbildung 26: Extrahierte Spektren von jedem gefundenen chromatografischen Peak im TIC jeder Analyse.




Abbildung 27: Zuordnung der Ladungen zu jedem Ladungscluster (links) und massendekonvolvierte Spektren des intakten monoklonalen Antikörpers (rechts) für die erste Analyse.




Abbildung 28: Integriertes Massenspektrum jeder Analyse nach Entfaltung.

3.3.1. Framework zur Verarbeitung von Raman-Spektroskopiedaten

Die Erweiterung von StreamFind ist nicht nur eng mit der Entwicklung und/oder Integration neuer Verarbeitungsschritte für massenspektrometrische Daten verbunden, sondern auch mit der Integration von Datenverarbeitungsfunktionen für andere Datentypen. Dies kann den Umfang und die Anwendungsbreite von StreamFind weiter erhöhen. So wurde im Plattform-Backend eine Analyseklasse implementiert, um verschiedene Datentypen zu harmonisieren. Im Rahmen von AP 6 wurden Datenverarbeitungsschritte für die Analyse und Verarbeitung von Raman-Spektroskopiedaten entwickelt bzw. integriert. Thissen et al. (2023)⁵⁶ stellten während der Projektlaufzeit eine innovative Kopplung von LC und Raman-Spektroskopie vor, die zu einem dreidimensionalen Datensatz (d. h. Elutionszeit, Raman-Verschiebung und Intensität) ohne derzeit kompatible Datenverarbeitungssoftware führte. Vor diesem Hintergrund wurden in StreamFind Datenverarbeitungsfunktionen für die Handhabung und Auswertung des dreidimensionalen Datensatzes entwickelt. In Abbildung 29 ist ein dreidimensionales Diagramm dargestellt, das nicht nur die gemittelten Raman-Spektren des Wirkstoffs (API, Active Pharmaceutical Ingredient) eines Arzneimittels, sondern auch die mittels LC getrennten Formulierungsbestandteile zeigt. Die dreidimensionale Darstellung wurde nach der Analyse der Rohdaten, der Integration des Chromatogramms (d. h. Elutionszeit versus kumulatives Raman-Signal), der Unterteilung der Daten auf der Grundlage der gefundenen chromatografischen Peaks, die den Substanzen entsprechen, der Glättung und Basislinienkorrektur jedes Raman-Spektrums für jede Elutionszeit und schließlich der Mittelung der Spektren innerhalb jedes chromatografischen Peaks zur Zusammenfassung des Raman-Spektrums jeder Substanz erstellt, wie in Abbildung 29 dargestellt. In einer kürzlich erschienenen Veröffentlichung von Thissen et al.⁵⁷ wurde eine Demonstration der StreamFind-Raman-Datenverarbeitung gezeigt. Dabei wurden verschiedene monoklonale Antikörperprodukte mittels SEC-Raman-Datenverarbeitung und -analyse unterschieden.

⁵⁶ Thissen, J., Klassen, M. D., Constantinidis, P., Hacker, M. C., Breitreutz, J., Teutenberg, T., & Fischer, B. (2023). Online Coupling of Size Exclusion Chromatography to Capillary Enhanced Raman Spectroscopy for the Analysis of Proteins and Biopharmaceutical Drug Products. *Analytical Chemistry*, 95(48), 17868–17877. <https://doi.org/10.1021/acs.analchem.3c03991>

⁵⁷ Thissen, J., Klassen, M. D., Fischer, B., Hacker, M. C., Breitreutz, J., Teutenberg, T., & Cunha, R. (2025). StreamFind: data processing workflows for qualification and quantification of biopharmaceutical drug products analyzed by size exclusion chromatography coupled to capillary-enhanced Raman spectroscopy. *Analytical and Bioanalytical Chemistry*, 417(19), 4469–4480. <https://doi.org/10.1007/s00216-025-05964-3>




Abbildung 29: Diagramm der verarbeiteten dreidimensionalen Daten aus der Kopplung von LC mit der Ramanspektroskopie, wobei jedes Spektrum einer Substanz (d. h. einem aktiven Produktbestandteil (G1_T2) und anderen Formulierungsbestandteilen (G2_T3 und G3_T4)) in einem pharmazeutischen Produkt entspricht.

3.4. Framework für die Analyse von maschinellem Lernen

Statistische Analysen sind der Schlüssel zur Zusammenfassung von Daten und zum Abrufen „verborgener“ Informationen in großen Datensätzen. Zusammen mit der höheren Verfügbarkeit von Daten haben die aktuellen Entwicklungen bei den Algorithmen für maschinelles Lernen Möglichkeiten für analytische Labore geschaffen, die „Dateneinblicke“ zu verbessern. Die Nutzbarkeit solcher Tools kann jedoch für nicht fachkundige Benutzer, wie z. B. Ingenieur-, Chemie- und Biologieabsolventen und Labortechniker, komplex sein. Vor diesem Hintergrund wurde eine Data-Processing-Engine entwickelt, die auf statistische Analysen spezialisiert ist. In

dieser sog. StatisticEngine können Benutzer statistische Methoden auf einfache tabellarische Daten anwenden. Es wurden Datenvorverarbeitungsschritte (z. B. Skalierung und Mittelwertzentrierung) entwickelt, um die Verbesserung der statistischen Analyse zu unterstützen. Die Implementierung der StatisticEngine besteht im Wesentlichen in der Erstellung eines StatisticModel auf der Grundlage von Trainings- und Testdaten, die für die Vorhersage verwendet werden können. Ein statistisches Modell ist eine Unterklasse von Ergebnissen, die ein Modell einer bestimmten statistischen Technik darstellt (z. B. Hauptkomponentenanalyse (PCA), K-Nearest Neighbours (KNN), Multivariate Curve Resolution (MCR), Random Forest usw.). Bisher wurden PCA, KNN und zwei Arten von MCR-Modellen implementiert. Ein wichtiger Aspekt von StreamFind ist die Wiederverwendung von Datenverarbeitungsmodulen innerhalb anderer Datenverarbeitungsmodule. Beispielsweise können Ergebnisse in Tabellenform von einer RamanEngine an eine StatisticEngine zur weiteren Datenanalyse übergeben werden. Ein Beispiel für einen solchen Transfer findet sich in einem Artikel⁵⁸ auf der github.io-Seite⁵⁹ von StreamFind, in dem Ergebnisse in Tabellenform von einer RamanEngine und einer MassSpecEngine zusammengeführt und für überwachte und unüberwachte statistische Analysen verwendet werden.

4. Nachhaltigkeit und Kontinuität der Projektergebnisse

Die Entwicklung von StreamFind erfolgte mit Blick auf den Einsatz als Open-Source-Projekt. Zu diesem Zweck wurden Backend und Frontend mit einer relativ einfachen Verbindung unter Verwendung des Shiny R-Pakets entwickelt. Dies bedeutet, dass die Wartung und Erweiterung von StreamFind in der Programmiersprache R erfolgt, wodurch der Aufwand für Entwickler und Wartungsbeauftragte minimiert und die nachhaltige Kontinuität der Projektergebnisse gewährleistet wird. Die Kontinuität wird auch durch die Förderung der Nutzung sichergestellt. Daher wurde das Netzwerk von StreamFind während des Projekts erweitert, um die weitere Nutzung und Entwicklung zu fördern (Abbildung 30). Bereits während des Projekts wurden weitere Projekte und Kooperationsaktivitäten durchgeführt, bei denen die Datenverarbeitungsfähigkeiten von StreamFind angewendet und andere Nutzer aktiv einbezogen wurden.

⁵⁸ https://odea-project.github.io/StreamFind/articles/demo_paracetamol_fusion.html

⁵⁹ <https://odea-project.github.io/StreamFind/index.html>

a)



b)



Abbildung 30: Die initiale Liste der unterstützenden Partner (a) und die aktuelle Liste der Netzwerkpartner für das streamFind-Projekt (b).

5. Fazit

Im Rahmen des Projekts streamFind wurde ein umfassendes, modulares und erweiterbares Open-Source-Framework für die Zusammenstellung von Datenverarbeitungs-Workflows sowie für die Analyse und Interpretation komplexer massenspektrometrischer Datensätze entwickelt. Während des gesamten Projekts wurden die größten Herausforderungen im Bereich des Non-Target-Screenings adressiert, indem standardisierte Datenstrukturen, reproduzierbare Workflows und harmonisierte Verarbeitungsschritte integriert wurden, die die Transparenz und Vergleichbarkeit erheblich verbessern. Das daraus resultierende R-Paket StreamFind bietet ein robustes Backend für die Verarbeitung von LC-HRMS-Daten, ergänzt durch ein flexibles Frontend, das interaktive Analysen und die automatisierte Erstellung von Berichten unterstützt. Eine wichtige Errungenschaft ist die Entwicklung nativer, leistungsstarker Algorithmen (d. h. Feature-Erkennung, Isotopen-Annotation, Matrix-Suppression-Korrektur, Fold-Change-Analyse und Gap-Filling), die die analytische Zuverlässigkeit verbessern und die Abhängigkeit von proprietärer Software verringern. Zusätzliche Integrationen, darunter MetFrag für die In-silico-Fragmentierung und Tools zur Erzeugung von Transformationsprodukten, erweitern die Fähigkeit der Plattform, bekannte und unbekannte Chemikalien im Wasserkreislauf zu identifizieren. Darüber hinaus konnte im Rahmen des Projekts demonstriert werden, wie eine Erweiterbarkeit der Plattform über den ursprünglichen Umfang hinaus möglich ist. Dies unterstreicht die Vielseitigkeit des Systems und seinen Wert für verschiedene wissenschaftliche Fachdomänen. Insgesamt schafft streamFind eine nachhaltige Grundlage für eine moderne, FAIR-konforme Umweltdatenanalyse. Seine offene, modulare Architektur gewährleistet langfristige Wartbarkeit, fördert die Entwicklung der

Community und ermöglicht Forschern und Praktikern die Durchführung fortschrittlicher, transparenter und reproduzierbarer NTS-Workflows. Das Projekt leistet somit einen bedeutenden Beitrag zur Umweltüberwachung, zur Bewertung der Wasserqualität und zur breiteren Einführung datengesteuerter Methoden in der analytischen Wissenschaft.